ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

LAB ASSIGNMENT 01

Project: DATA PREPROCESSING

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

Lê Quốc Thiện (23127481)

Phạm Quang Thịnh (23127485)

Giảng viên hướng dẫn:

TS. Lê Hoài Bắc

ThS. Lê Nhựt Nam

ThS. Nguyễn Ngọc Đức

Ngày 1 tháng 3 năm 2026

Mục lục

1 TIỀN XỬ LÝ DỮ LIỆU HÌNH ẢNH (DIGITAL IMAGE DATA) 1

1.1 Lựa chọn tập dữ liệu . . . 1

1.2 Tải và thay đổi kích thước (Loading and Resizing) . . . 1

1.2.1 Lý do thực hiện và cài đặt . . . 1

1.2.2 Kết quả trực quan và phân tích sự đánh đổi . . . 2

1.2.3 Đánh giá chung về kĩ thuật . . . 3

1.3 Chuyển đổi sang ảnh xám (Grayscale conversion) . . . 3

1.3.1 Lý do tiền xử lý . . . 3

1.3.2 Phân tích sự giữ lại thông tin . . . 4

1.3.3 Đánh giá chung về kỹ thuật . . . 5

1.4 Chuẩn hóa (Normalization) . . . 5

1.4.1 Kỹ thuật thực hiện . . . 5

1.4.2 Kết quả và Phân tích . . . 6

1.4.3 Đánh giá chung về kỹ thuật . . . 7

1.5 Phát hiện cạnh (Edge Detection - Optional Bonus) . . . 8

1.5.1 Các thuật toán áp dụng . . . 8

1.5.2 Kết quả và phân tích . . . 9

1.5.3 Đánh giá chung về kĩ thuật . . . 10

1.6 Batch Processing trong xử lý ảnh . . . 10

1.6.1 Các kỹ thuật tiền xử lý được áp dụng . . . 10

1.6.2 Kết quả thực nghiệm . . . 11

1.6.3 Đánh giá chung . . . 11

2 TIỀN XỬ LÝ DỮ LIỆU BẢNG (TABULAR DATA) 12

2.1 Lựa chọn tập dữ liệu (Dataset Selection) . . . 12

2.2 Xử lý giá trị thiếu (Handling Missing Values) . . . 12

2.2.1 Phân tích mẫu dữ liệu thiếu . . . 12

2.2.2 Lý do và Kỹ thuật thực hiện . . . 13

2.2.3 Kết quả và Phân tích . . . 13

2.3 Chuẩn hóa dữ liệu (Data Normalization) . . . 14

2.3.1 Kỹ thuật thực hiện . . . 14

2.3.2 Lý do và Mục tiêu 14
2.3.3 Kết quả trực quan và Phân tích so sánh 14
2.3.4 So sánh và Kết luận 16
2.4 Mã hóa biến phân loại (Categorical Encoding) 17
2.4.1 Xác định biến phân loại 17
2.4.2 Chi tiết triển khai và Thảo luận 17
2.5 Lựa chọn đặc trưng (Feature Selection) 18
2.5.1 Phương pháp sử dụng 18
2.5.2 Kết quả thực nghiệm và Giải thích 19
2.5.3 Kết luận cuối cùng 20

3 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN (TEXTUAL DATA) - BONUS 21
3.1 Lựa chọn tập dữ liệu (Dataset Selection) 21
3.2 Tách từ (Tokenization) 22
3.2.1 Triển khai các kỹ thuật thực hiện 22
3.2.2 So sánh các chiến lược tách từ 23
3.2.3 Thảo luận và Ưu điểm đối với tập dữ liệu IMDB 23
3.3 Loại bỏ từ dừng (Removing Stop Words) 23
3.3.1 Nhận diện các từ dừng phổ biến trong tập dữ liệu 24
3.3.2 Thực nghiệm loại bỏ và tác động đến kích thước dữ liệu 24
3.3.3 Phân tích tác động và khả năng giữ lại thông tin 24
3.4 Gốc từ và Chuẩn hóa từ (Stemming and Lemmatization) 25
3.4.1 Triển khai thực nghiệm các thuật toán 25
3.4.2 So sánh kết quả thực nghiệm 25
3.4.3 Thảo luận về ưu điểm và nhược điểm đối với tập dữ liệu IMDB 26
3.5 Vector hóa văn bản (Text Vectorization) 27
3.5.1 Các kỹ thuật thực hiện 27
3.5.2 So sánh về số chiều và độ thưa (Dimensionality and Sparsity) 27
3.5.3 Phân tích và Thảo luận 28

4 TIỀN XỬ LÝ DỮ LIỆU THỜI GIAN (TEMPORAL DATA) - BONUS 29
4.1 Lựa chọn tập dữ liệu (Dataset Selection) 29
4.2 Xử lý định dạng thời gian (Parsing Date and Time) 29
4.2.1 Kỹ thuật triển khai 29

4.2.2 Kết quả và phân tích dựa trên thực nghiệm 30
4.2.3 Đánh giá chung về kỹ thuật 31
4.3 Xử lý khoảng trống thời gian (Handling Time Gaps) 31
4.3.1 Phân tích và Kỹ thuật triển khai 31
4.3.2 Kết quả và So sánh dựa trên thực nghiệm 32
4.3.3 Đánh giá chung về kỹ thuật 33
4.4 Trích xuất đặc trưng thời gian (Extracting Time-Based Features) 33
4.4.1 Kỹ thuật thực hiện: Làm giàu đặc trưng và biến chỉ báo 33
4.4.2 Phân tích kết quả thực nghiệm 34
4.4.3 Đánh giá chung về kỹ thuật 35
4.5 Tái lấy mẫu dữ liệu (Resampling Time Series Data) 36
4.5.1 Kỹ thuật áp dụng và Chi tiết cài đặt 36
4.5.2 Kết quả và Phân tích sâu sắc dựa trên thực nghiệm 36
4.5.3 Đánh giá chung về kỹ thuật 38
4.6 Đặc trưng trễ và Cửa sổ trượt (Lag Features & Rolling Windows) 38
4.6.1 Chi tiết kỹ thuật triển khai 38
4.6.2 Kết quả và Phân tích sâu sắc dựa trên thực nghiệm 39
4.6.3 Đánh giá chung về kỹ thuật 40

1 TIỀN XỬ LÝ DỮ LIỆU HÌNH ẢNH (DIGITAL IMAGE DATA)

1.1 Lựa chọn tập dữ liệu

- **Tên tập dữ liệu:** Chest X-Ray Images - Hình ảnh X-quang ngực chẩn đoán viêm phổi.
- **Nguồn gốc và link tải:** Tập dữ liệu được cung cấp bởi Paul Mooney trên nền tảng Kaggle.
  Đường dẫn: https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia
- **Đặc điểm dữ liệu:**
  - Số lượng: 5,856 ảnh định dạng JPEG.
  - Cấu trúc: Chia thành 3 tập (train, test, val) với 2 nhãn chính là: "Normal" (Bình thường) và "Pneumonia" (Viêm phổi).
  - Kích thước gốc: Không đồng nhất, dao động từ khoảng 1000 x 1000 pixels đến những ảnh độ phân giải cao lên tới hơn 2000 x 2000 pixels.
- **Mô tả tóm tắt:** Tập dữ liệu chứa các hình ảnh X-quang lồng ngực được chụp từ các bệnh nhi. Đây là dữ liệu y tế thực tế, có độ nhiễu nhất định và sự khác biệt về góc chụp, cường độ sáng.

1.2 Tải và thay đổi kích thước (Loading and Resizing)

1.2.1 Lý do thực hiện và cài đặt

- **Mục đích:** Đưa tất cả hình ảnh về cùng một kích thước cố định nhằm đảm bảo tính đồng nhất khi đưa vào mô hình CNN và thuận tiện cho việc xử lý theo từng batch.
- **Kỹ thuật triển khai:** Nhóm sử dụng thư viện OpenCV, cụ thể là hàm `cv2.imread()` để đọc ảnh và `cv2.resize()` để thay đổi kích thước ảnh với phương pháp nội suy `INTER_AREA`. Trong quá trình thực hiện, nhóm đã thử nghiệm nhiều kích thước khác nhau để quan sát sự thay đổi về chất lượng hình ảnh và tài nguyên sử dụng.

1.2.2 Kết quả trực quan và phân tích sự đánh đổi

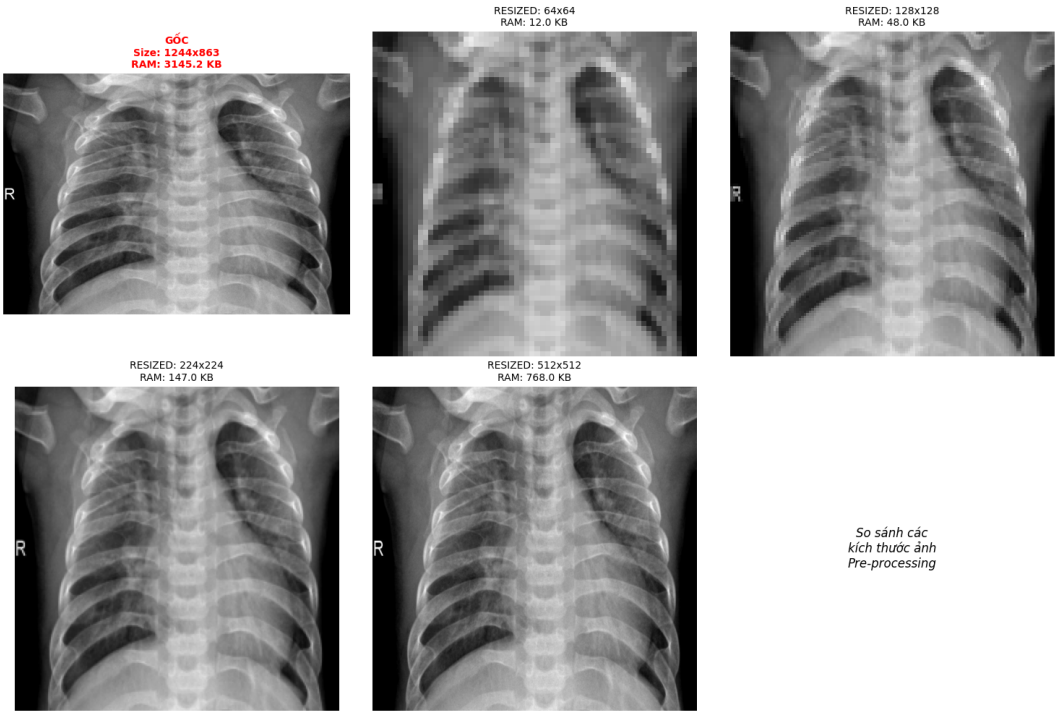

Hình 1: So sánh chất lượng hình ảnh ở các kích thước khác nhau

Dựa trên kết quả trực quan (Hình 1), nhóm tiến hành so sánh thêm về dung lượng bộ nhớ và mức độ giữ lại chi tiết hình ảnh ở từng kích thước:

- **Ảnh gốc** (1244×863)**:** Dung lượng khoảng 3145.2 KB. Ảnh có độ chi tiết cao nhưng kích thước lớn, có thể gây khó khăn khi huấn luyện với số lượng lớn ảnh trên máy tính cá nhân.
- 64×64**:** Dung lượng giảm còn 12.0 KB. Tuy nhiên, ảnh bị vỡ hạt rõ rệt, nhiều cấu trúc phổi (có thể là vùng tổn thương nhỏ) gần như không còn phân biệt được.
- 128×128**:** Dung lượng khoảng 48.0 KB. So với 64×64, độ nét cải thiện nhưng vẫn chưa đủ rõ đối với các chi tiết bệnh lý nhỏ.
- 224×224**:** Dung lượng khoảng 147.0 KB. Ở mức này, các cấu trúc giải phẫu chính (xương sườn, vùng phổi, vòm hoành) vẫn được giữ lại tương đối rõ, trong khi dung lượng đã giảm đáng kể so với ảnh gốc.
- 512×512**:** Dung lượng khoảng 768.0 KB. Chất lượng hình ảnh cao, tuy nhiên chi phí bộ nhớ và thời gian xử lý tăng đáng kể, trong khi sự cải thiện về đặc trưng không quá khác biệt so với 224×224 trong bài toán phân loại cơ bản.

Kết luận: Sau khi thử nghiệm và quan sát trực quan, nhóm chọn kích thước 224×224 là phù hợp nhất cho dataset này. Kích thước này đảm bảo giữ được các đặc trưng quan trọng của ảnh X-ray, đồng thời vẫn phù hợp với khả năng tính toán của máy cá nhân. Ngoài ra, đây cũng là kích thước phổ biến trong nhiều kiến trúc CNN như ResNet hoặc VGG, giúp thuận tiện nếu mở rộng sang bước huấn luyện mô hình sau này.

1.2.3 Đánh giá chung về kĩ thuật

Việc thay đổi kích thước ảnh là bước gần như bắt buộc khi dữ liệu có kích thước không đồng nhất hoặc khi sử dụng các mô hình CNN yêu cầu đầu vào cố định. Kỹ thuật này đặc biệt cần thiết trong các trường hợp:

- Huấn luyện mô hình Deep Learning với batch processing.
- Làm việc với dataset có ảnh gốc độ phân giải cao gây tốn bộ nhớ.
- Cần chuẩn hóa đầu vào để đảm bảo tính ổn định trong quá trình huấn luyện.

Tuy nhiên, không phải lúc nào cũng nên giảm kích thước quá mạnh. Trong các bài toán yêu cầu phát hiện chi tiết rất nhỏ, việc resize xuống quá thấp có thể làm mất thông tin quan trọng. Ngoài ra, nếu tài nguyên phần cứng cho phép và bài toán yêu cầu giữ tối đa độ chi tiết, có thể cân nhắc sử dụng kích thước lớn hơn hoặc giữ nguyên ảnh gốc.

1.3 Chuyển đổi sang ảnh xám (Grayscale conversion)

1.3.1 Lý do tiền xử lý

- **Mục đích:** Chuyển đổi ảnh từ không gian màu RGB (3 kênh) sang ảnh mức xám (1 kênh) nhằm giảm số chiều dữ liệu đầu vào và loại bỏ các thông tin màu không cần thiết đối với bài toán.
- **Đối với dữ liệu Chest X-Ray:**
  - *Giảm chi phí tính toán:* Ảnh sau khi chuyển sang 1 kênh giúp giảm đáng kể bộ nhớ sử dụng và số phép tính trong các lớp tích chập.
  - *Tập trung vào cấu trúc:* Các dấu hiệu bệnh lý trong ảnh X-ray chủ yếu thể hiện qua mức độ sáng tối và kết cấu vùng phổi, thay vì thông tin màu sắc.
  - *Đơn giản hóa dữ liệu:* Loại bỏ các sai lệch nhỏ giữa các kênh màu do quá trình lưu trữ hoặc thiết bị chụp.

- **Thảo luận về sự đánh đổi:**
  - Phù hợp với các ảnh vốn mang tính đơn sắc như X-ray, MRI hoặc ảnh tài liệu.
  - Không phù hợp với các bài toán mà màu sắc là đặc trưng phân loại quan trọng (ví dụ: phân loại trái cây, trang phục, tổn thương da).

1.3.2 Phân tích sự giữ lại thông tin

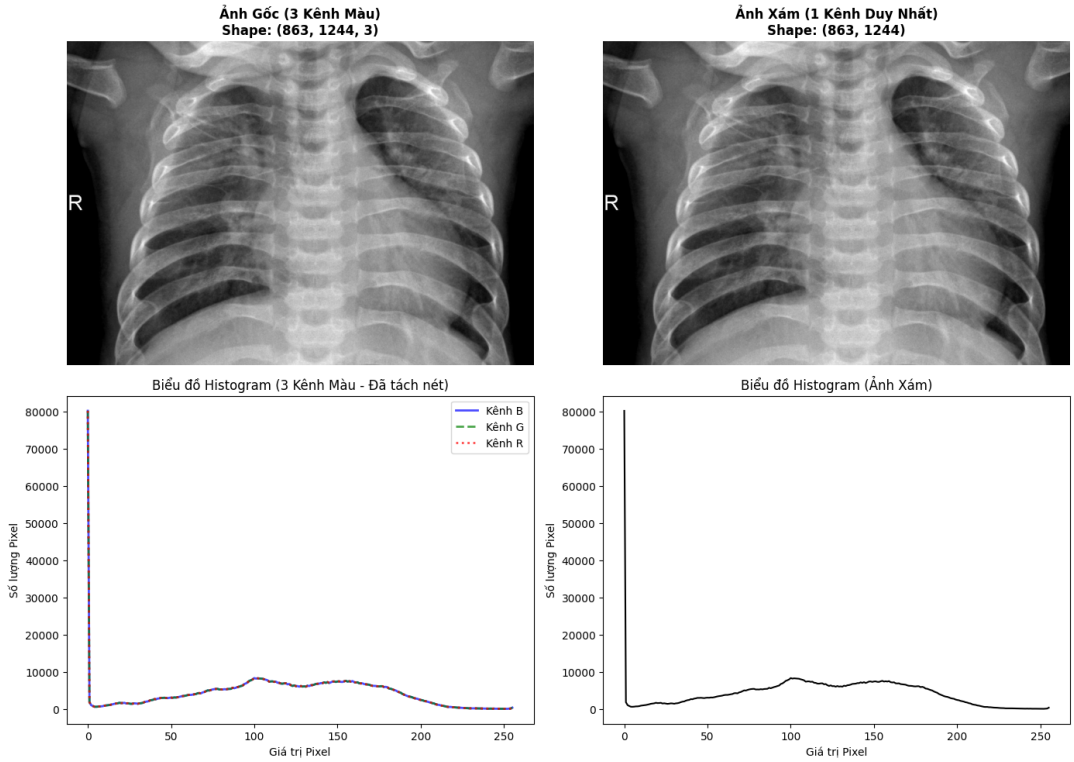

Hình 2: So sánh ảnh RGB và ảnh xám cùng biểu đồ Histogram

Dựa trên quan sát trực quan và biểu đồ histogram (Hình 2), nhóm rút ra một số nhận xét:

- **Quan sát trực quan:** Ảnh sau khi chuyển sang Grayscale gần như không thay đổi về độ tương phản và hình dạng cấu trúc. Các vùng phổi và xương sườn vẫn được thể hiện rõ ràng.
- **Phân tích Histogram:** Ba kênh R, G, B trong ảnh gốc có phân phối gần như trùng nhau. Điều này cho thấy ảnh ban đầu tuy lưu ở định dạng 3 kênh nhưng thực chất mang bản chất đơn sắc. Sau khi chuyển sang ảnh xám, phân phối cường độ sáng gần như không thay đổi. Điều này giải thích vì sao sau khi chuyển sang Grayscale, sự khác biệt gần như không đáng kể. Tuy nhiên, bước tiền xử lý này vẫn cần thiết để đảm bảo tính nhất quán của toàn bộ pipeline và tránh dư thừa dữ liệu đầu vào.

Kết luận: Đối với bộ dữ liệu Chest X-Ray, việc chuyển sang Grayscale hầu như không làm mất thông tin quan trọng, trong khi giúp giảm kích thước dữ liệu và đơn giản hóa quá trình xử lý.

1.3.3 Đánh giá chung về kỹ thuật

Chuyển đổi sang ảnh xám là một bước tiền xử lý phù hợp trong các bài toán mà thông tin màu sắc không đóng vai trò quan trọng. Đối với dữ liệu Chest X-Ray, ảnh vốn mang bản chất đơn sắc nên việc giữ lại 3 kênh RGB là không cần thiết và làm tăng kích thước dữ liệu đầu vào.

Kỹ thuật này đặc biệt hữu ích trong các trường hợp:

- Dữ liệu có bản chất đơn sắc (X-ray, MRI, tài liệu scan).
- Cần giảm số chiều đầu vào để tiết kiệm bộ nhớ và tăng tốc độ huấn luyện.
- Muốn tập trung vào đặc trưng cấu trúc và cường độ sáng thay vì màu sắc.

Tuy nhiên, không nên áp dụng Grayscale một cách mặc định cho mọi bài toán. Trong các bài toán phân loại mà màu sắc là đặc trưng quan trọng (ví dụ: nhận diện thực phẩm, trang phục, tổn thương da), việc chuyển sang ảnh xám có thể làm mất thông tin phân biệt giữa các lớp dữ liệu.

Do đó, quyết định sử dụng Grayscale cần dựa trên bản chất của dữ liệu và mục tiêu bài toán thay vì chỉ nhằm mục đích giảm kích thước dữ liệu.

1.4 Chuẩn hóa (Normalization)

1.4.1 Kỹ thuật thực hiện

Nhóm đã triển khai và so sánh ba kỹ thuật chuẩn hóa phổ biến trong tiền xử lý hình ảnh nhằm đưa các giá trị pixel về một thang đo ổn định:

- **Pixel Scaling (Min-Max [0, 1]):** Toàn bộ giá trị pixel được chia cho 255 để đưa về khoảng $[0, 1]$. Kỹ thuật này giữ nguyên mối quan hệ tuyến tính giữa các pixel.
- **Pixel Scaling (Min-Max [-1, 1]):** Dữ liệu được ánh xạ về khoảng $[-1, 1]$. Kỹ thuật này thường được sử dụng cho các mô hình yêu cầu giá trị trung tâm là 0, chẳng hạn như khi sử dụng hàm kích hoạt *tanh*.
- **Standardization (Z-score Normalization):** Biến đổi dữ liệu dựa trên giá trị trung bình (μ) và độ lệch chuẩn (σ) của toàn bộ tập dữ liệu mẫu theo công thức: $x' = (x - \mu)/\sigma$.

1.4.2 Kết quả và Phân tích

Bảng 1: So sánh thống kê các phương pháp chuẩn hóa dữ liệu ảnh

Metric	Original (0-255)	Min-Max [0,1]	Min-Max [-1,1]	Standardization
Min	0.000000	0.00000	-1.000000	-1.997886
Max	255.000000	1.00000	1.000000	2.551778
Mean	111.977725	0.439128	-0.121743	$-6.907058 \times 10^{-17}$
Std Dev	56.048093	0.219796	0.439593	1.000000

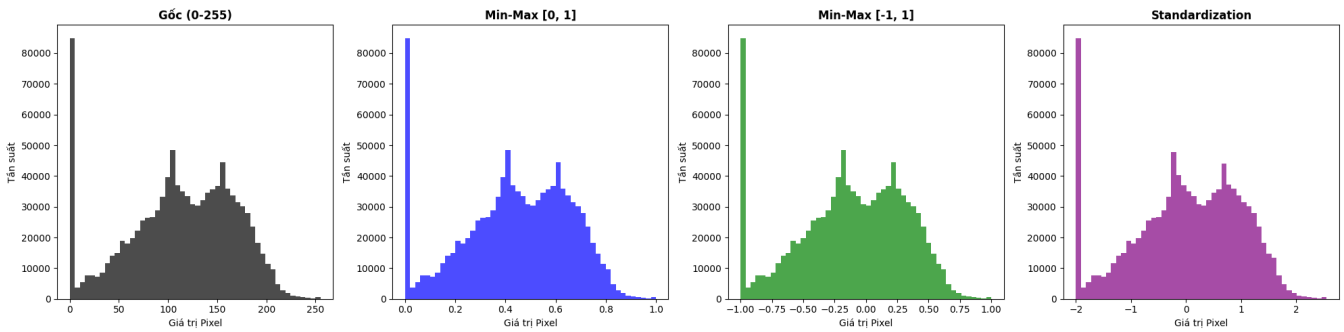

Hình 3: So sánh phân phối Histogram của ảnh gốc và các phương pháp chuẩn hóa (Min-Max [0,1], Min-Max [-1,1], Standardization)

Dựa trên bảng so sánh thống kê và các biểu đồ Histogram thực nghiệm (Hình 3), nhóm rút ra các phân tích định lượng sau:

1. **Phân tích số liệu thống kê:**

   - Ở trạng thái **gốc (0–255)**, ảnh có giá trị trung bình khoảng 112.0 và độ lệch chuẩn khoảng 56.0. Khoảng giá trị rộng, dữ liệu không được chuẩn hóa, có thể ảnh hưởng đến độ ổn định của quá trình tối ưu.
   - Với **Min-Max [0,1]**, toàn bộ dữ liệu được đưa về khoảng $[0, 1]$, giá trị trung bình còn khoảng 0.439 và độ lệch chuẩn giảm xuống 0.219. Phương pháp này giúp thu nhỏ thang đo nhưng vẫn giữ nguyên hình dạng phân phối ban đầu.
   - Với **Min-Max [-1,1]**, dữ liệu được dịch chuyển để cân đối quanh 0 hơn (Mean xấp xỉ -0.121). Cách chuẩn hóa này phù hợp nếu mô hình yêu cầu đầu vào có tâm gần 0.
   - Sau khi **Standardization**, giá trị trung bình xấp xỉ 0 (-6.9×10^{-17}) và độ lệch chuẩn xấp xỉ 1. Điều này cho thấy dữ liệu đã được chuẩn hóa theo đúng mục tiêu thống kê của phương pháp Z-score.

2. **Tác động đến phân phối:**

   - Quan sát 4 biểu đồ Histogram cho thấy hình dạng tổng thể của phân phối được giữ nguyên. Các đỉnh và vùng lõm vẫn duy trì cấu trúc tương đối tương đồng, chỉ thay đổi về vị trí và độ giãn trên trục hoành.
   - Nhóm nhận thấy sự khác biệt nhỏ giữa các biểu đồ (dễ thấy nhất là Standardization so với các biểu đồ còn lại) chủ yếu xuất phát từ phạm vi giá trị và cách chia bin của histogram, không phải sự thay đổi bản chất phân phối.
   - Điều này cho thấy các kỹ thuật chuẩn hóa (Min-Max và Z-score) chỉ thực hiện phép biến đổi tuyến tính, nhằm thay đổi thang đo và trung tâm dữ liệu, nhưng không làm mất đi đặc trưng hình thái hay thông tin chẩn đoán quan trọng trong ảnh X-quang.

3. **Ý nghĩa đối với mô hình học sâu:**

   - *Tăng tốc hội tụ:* Việc đưa dữ liệu về khoảng nhỏ giúp thuật toán Gradient Descent tìm được điểm cực tiểu của hàm mất mát nhanh hơn, tránh hiện tượng "zigzag" trong quá trình huấn luyện.
   - *Tránh bão hòa hàm kích hoạt:* Ngăn chặn việc các giá trị pixel quá lớn (như 255) đẩy các hàm kích hoạt (Sigmoid, Tanh) vào vùng bão hòa, nơi đạo hàm xấp xỉ bằng 0 gây ra hiện tượng triệt tiêu gradient.

Nhận xét chung: Nhóm nhận thấy ưu tiên kỹ thuật **Standardization** cho dataset này, vì nó không chỉ đưa dữ liệu về thang đo nhỏ mà còn đảm bảo tính ổn định về mặt thống kê, giúp mô hình ít bị ảnh hưởng hơn bởi các ảnh có độ sáng tối cực đoan.

1.4.3 Đánh giá chung về kỹ thuật

Normalization (chuẩn hóa) là bước tiền xử lý gần như cần thiết trong hầu hết các bài toán học sâu, đặc biệt khi sử dụng các thuật toán tối ưu dựa trên Gradient Descent. Việc đưa dữ liệu về cùng một thang đo giúp mô hình học ổn định hơn và giảm sự phụ thuộc vào độ sáng tuyệt đối của ảnh. Vì thế ta nên sử dụng kĩ thuật chuẩn hóa khi:

- Huấn luyện mạng nơ-ron tích chập (CNN) hoặc các mô hình Deep Learning.
- Dữ liệu có khoảng giá trị rộng hoặc độ sáng giữa các ảnh không đồng đều.
- Khi sử dụng các hàm kích hoạt nhạy với giá trị đầu vào.

1.5 Phát hiện cạnh (Edge Detection - Optional Bonus)

1.5.1 Các thuật toán áp dụng

Nhóm thực nghiệm ba thuật toán phát hiện cạnh phổ biến nhằm trích xuất đặc trưng hình dạng từ ảnh X-quang:

- **Sobel:** Sử dụng bộ lọc đạo hàm bậc nhất để tính gradient cường độ sáng theo phương ngang và dọc. Phương pháp này làm nổi bật các vùng có sự thay đổi cường độ đột ngột.
- **Prewitt:** Tương tự Sobel nhưng sử dụng kernel đơn giản hơn. Kết quả thường rõ biên tổng quát nhưng nhạy cảm hơn với nhiễu.
- **Canny:** Thuật toán nhiều bước gồm làm mượt Gaussian, tính gradient, non-maximum suppression và hysteresis thresholding. Mục tiêu là tạo ra các đường biên mảnh và liên tục hơn.

1.5.2 Kết quả và phân tích

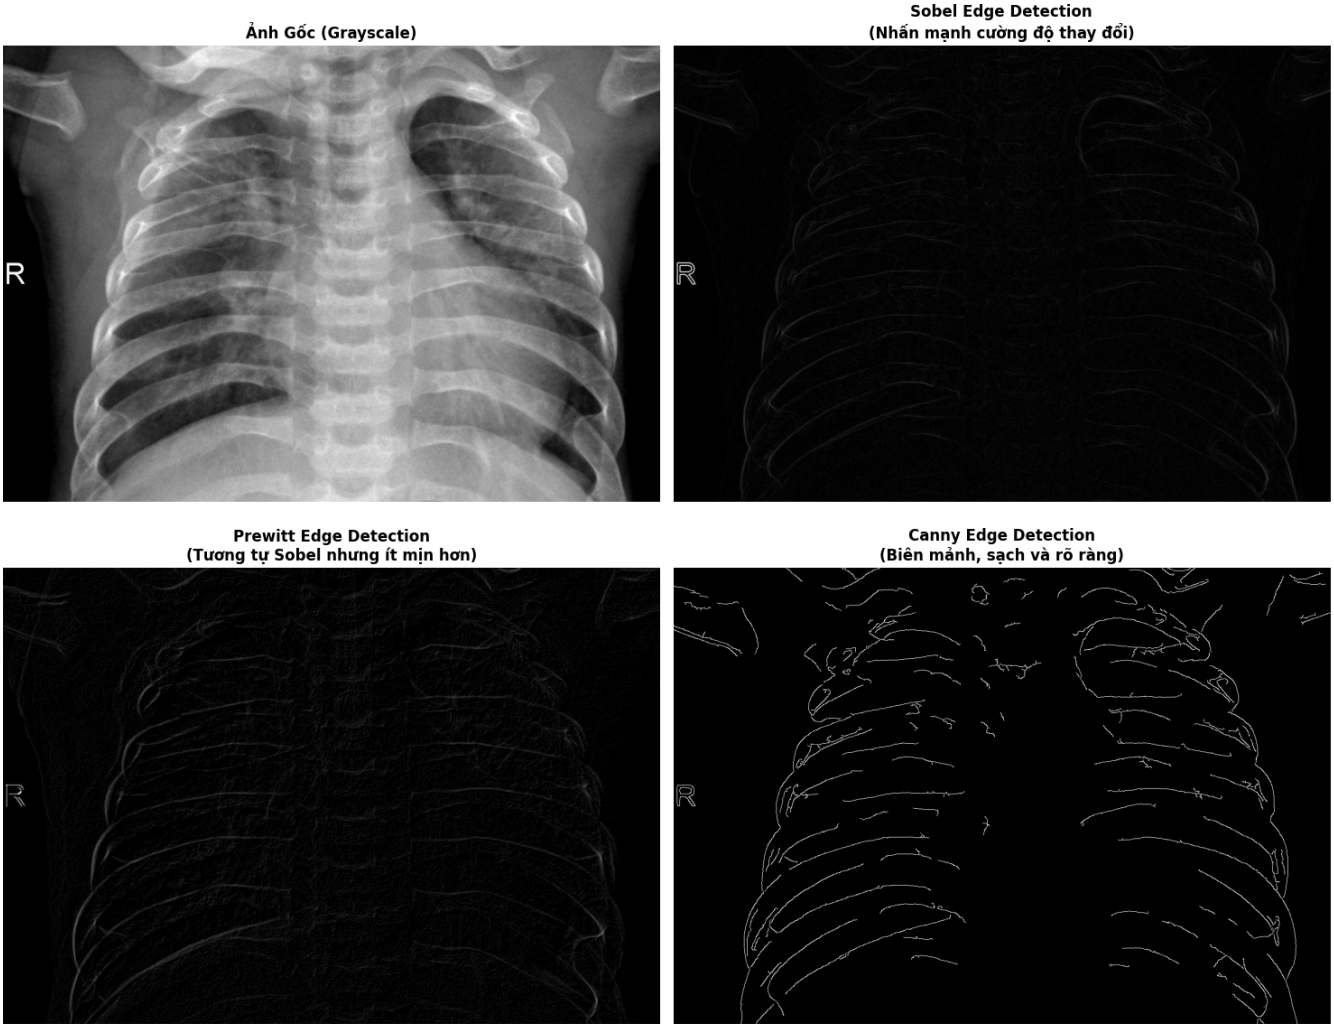

Hình 4: So sánh các phương pháp phát hiện biên trên ảnh X-quang

Dựa trên quan sát trực quan (Hình 4), nhóm rút ra một số nhận xét:

1. **So sánh các thuật toán:**
   - *Sobel:* Làm nổi bật các vùng thay đổi cường độ sáng, tuy nhiên biên còn mờ và độ tương phản thấp. Nhiều vùng nền vẫn xuất hiện nhiễu nhẹ.
   - *Prewitt:* Cho kết quả tương đối giống Sobel trong thực nghiệm này. Các đường biên được phát hiện nhưng vẫn chưa đủ rõ và còn lẫn nhiễu ở vùng phổi.
   - *Canny:* Tạo ra các đường biên mảnh và rõ hơn. Nhờ cơ chế lọc nhiễu và ngưỡng kép, ảnh cạnh sạch hơn và tập trung vào các cấu trúc lớn như xương sườn và khung lồng ngực.

2. **Ý nghĩa đối với dữ liệu Chest X-Ray:**
   - Giúp làm nổi bật khung xương sườn, xương đòn và ranh giới giữa các vùng giải phẫu.
   - Có thể hỗ trợ các bước nâng cao như phân vùng (segmentation) hoặc trích xuất đặc trưng hình dạng.
   - Tuy nhiên, ảnh sau khi phát hiện cạnh chỉ giữ lại thông tin biên và loại bỏ phần lớn thông tin cường độ, nên không phải lúc nào cũng phù hợp cho bài toán phân loại tổng quát.

Kết luận: Qua thực nghiệm, **Canny** được đánh giá là kỹ thuật hiệu quả nhất để trích xuất đặc trưng hình thái cho ảnh X-quang. Nó biến một bức ảnh giàu thông tin cường độ thành một ảnh tập trung vào đường nét, giúp mô hình tập trung tối đa vào cấu trúc và hình dạng của các cơ quan.

1.5.3 Đánh giá chung về kĩ thuật

Phát hiện biên giúp làm nổi bật các vùng có sự thay đổi cường độ sáng mạnh, từ đó nhấn mạnh cấu trúc và hình dạng trong ảnh X-quang. Sobel và Prewitt cho kết quả nhanh, đơn giản nhưng vẫn giữ lại khá nhiều chi tiết và nhiễu nhẹ. Trong khi đó, Canny tạo ra các đường biên mảnh, rõ ràng và ít nhiễu hơn.

Tuy nhiên, theo tìm hiểu, trong các mô hình CNN hiện đại, đặc trưng biên thường được tự động học ở các tầng đầu tiên. Vì vậy, nhóm nghĩ kỹ thuật này phù hợp khi cần phân tích đặc trưng thủ công hoặc hỗ trợ phân đoạn ảnh.

1.6 Batch Processing trong xử lý ảnh

1.6.1 Các kỹ thuật tiền xử lý được áp dụng

Trong giai đoạn tiền xử lý ảnh, nhóm áp dụng các kỹ thuật sau:

- **Resize ảnh** về kích thước cố định (224×224) để đảm bảo tính đồng nhất đầu vào cho mô hình.
- **Chuyển sang Grayscale** nhằm giảm số chiều dữ liệu và tập trung vào thông tin cường độ sáng.
- **Chuẩn hóa (Standardization)** đưa dữ liệu về phân phối có $\mu \approx 0$ và $\sigma \approx 1$ giúp mô hình hội tụ nhanh và ổn định hơn.
- **Batch Processing** để xử lý toàn bộ tập test một cách tự động, tối ưu thời gian và kiểm soát tài nguyên bộ nhớ.

Lưu ý: Nhóm không áp dụng kỹ thuật Edge Detection vì các mô hình CNN hiện đại có khả năng tự học đặc trưng biên thông qua các lớp tích chập ban đầu. Việc phát hiện biên thủ công có thể làm mất thông tin cường độ quan trọng trong ảnh X-ray và không mang lại lợi ích rõ rệt cho bài toán phân loại.

1.6.2 Kết quả thực nghiệm

Nhóm tiến hành xử lý toàn bộ tập test gồm **624 ảnh** thuộc hai lớp `NORMAL` và `PNEUMONIA`.

- **Tổng thời gian xử lý:** 6.86 giây
- **Tốc độ trung bình:** 0.0110 giây/ảnh
- **Dung lượng RAM tiết kiệm trung bình:** 4134.40 KB/ảnh
- **Mean trung bình sau chuẩn hóa:** $8.05 \times 10^{-18} \approx 0$
- **Độ lệch chuẩn trung bình sau chuẩn hóa:** 1.0

Phân tích và nhận xét

Kết quả cho thấy pipeline xử lý (Resize → Grayscale → Standardization) hoạt động ổn định và nhất quán trên toàn bộ tập dữ liệu:

- Giá trị **Mean xấp xỉ 0** và **Std xấp xỉ 1** trên toàn batch chứng minh bước Standardization được triển khai chính xác.
- Mức tiết kiệm RAM trung bình hơn **4MB/ảnh** cho thấy việc chuyển ảnh sang kích thước cố định và ảnh xám giúp giảm đáng kể chi phí bộ nhớ.
- Tốc độ xử lý dưới **0.01 giây/ảnh** thể hiện hệ thống có khả năng mở rộng tốt khi áp dụng cho tập dữ liệu lớn hơn.

1.6.3 Đánh giá chung

Batch Processing giúp tự động hóa toàn bộ quy trình tiền xử lý, đảm bảo tính đồng nhất giữa các ảnh và nâng cao hiệu suất xử lý. Kỹ thuật này đặc biệt cần thiết khi làm việc với tập dữ liệu lớn hoặc khi chuẩn bị dữ liệu cho huấn luyện mô hình học sâu.

Tuy nhiên, trong các hệ thống thời gian thực (real-time systems), cần cân nhắc giữa batch size và giới hạn bộ nhớ để tránh gây quá tải tài nguyên.

2 TIỀN XỬ LÝ DỮ LIỆU BẢNG (TABULAR DATA)

2.1 Lựa chọn tập dữ liệu (Dataset Selection)

- **Nguồn gốc:** Tập dữ liệu mô phỏng giao dịch thẻ tín dụng từ Kaggle: Credit Card Fraud Detection.
- **Kích thước:** Tập dữ liệu được lấy mẫu ngẫu nhiên (sampling) bao gồm 10,000 dòng và 23 cột thuộc tính.
- **Mô tả ngắn:** Dữ liệu chứa thông tin chi tiết về các giao dịch bao gồm số tiền (`amt`), dân số thành phố (`city_pop`), tọa độ địa lý và nhãn mục tiêu `is_fraud`.

2.2 Xử lý giá trị thiếu (Handling Missing Values)

2.2.1 Phân tích mẫu dữ liệu thiếu

- **Phân loại:** Qua kiểm tra thực tế bằng câu lệnh `df.isnull().sum()`, tập dữ liệu hiện tại không chứa giá trị thiếu (No missing values). Tuy nhiên, để xây dựng quy trình tiền xử lý hoàn chỉnh theo yêu cầu, nhóm vẫn thiết lập Pipeline xử lý cho hai biến quan trọng là `amt` và `city_pop`.
- **Trực quan hóa:** Nhóm sử dụng thư viện `missingno` để vẽ biểu đồ ma trận. Kết quả hiển thị các cột màu đen đặc, xác nhận tính toàn vẹn của dữ liệu đầu vào.

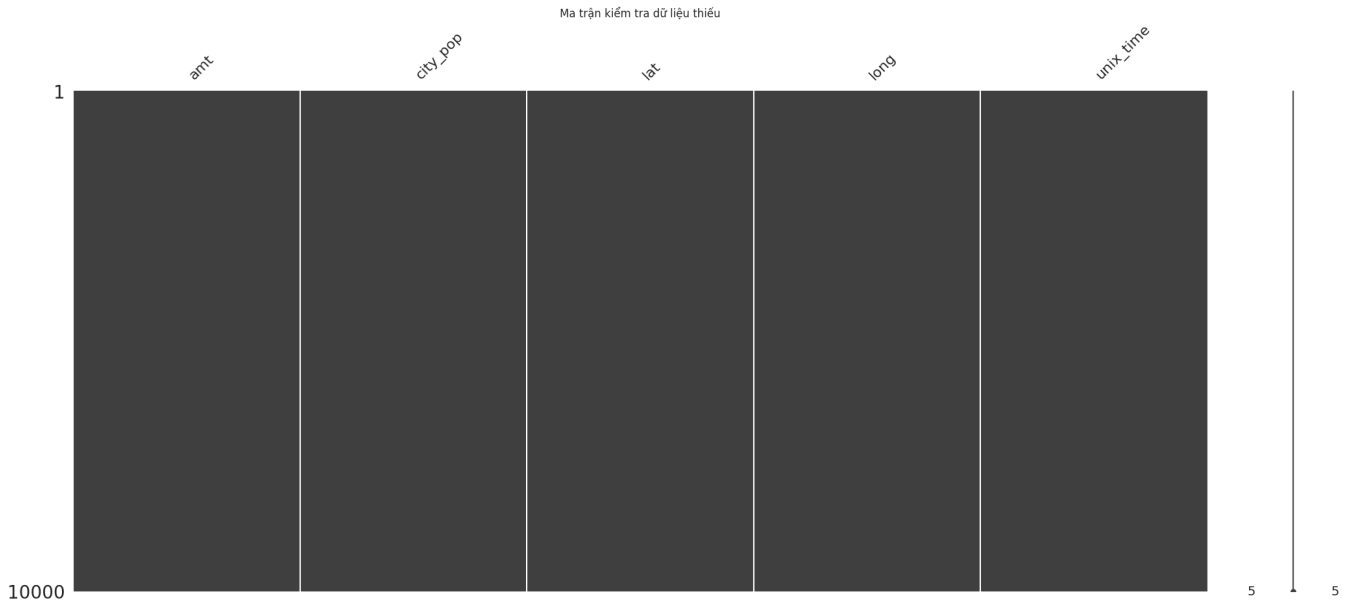

Hình 5: Trực quan hóa ma trận dữ liệu thiếu bằng Missingno

2.2.2 Lý do và Kỹ thuật thực hiện

- **Kỹ thuật sử dụng:**
  - **Median Imputation:** Áp dụng cho cột `amt`. Vì số tiền giao dịch thường có độ lệch lớn, sử dụng trung vị giúp đảm bảo tính đại diện mà không bị ảnh hưởng bởi nhiễu.
  - **K-NN Imputation ($K = 5$):** Áp dụng cho cột `city_pop`. Nhóm sử dụng thông tin địa lý (`lat`, `long`) để lấp đầy giá trị dựa trên các điểm lân cận, đảm bảo tính logic về mặt không gian.
- **Lý do lựa chọn:** Đảm bảo mô hình hoạt động ổn định trong trường hợp dữ liệu thực tế phát sinh lỗi thiếu hụt trong tương lai.

2.2.3 Kết quả và Phân tích

Sau khi thực hiện quy trình lấp đầy dữ liệu thiếu giả định cho đặc trưng số tiền (`amt`), nhóm tiến hành trực quan hóa để kiểm tra sự biến động của phân phối dữ liệu.

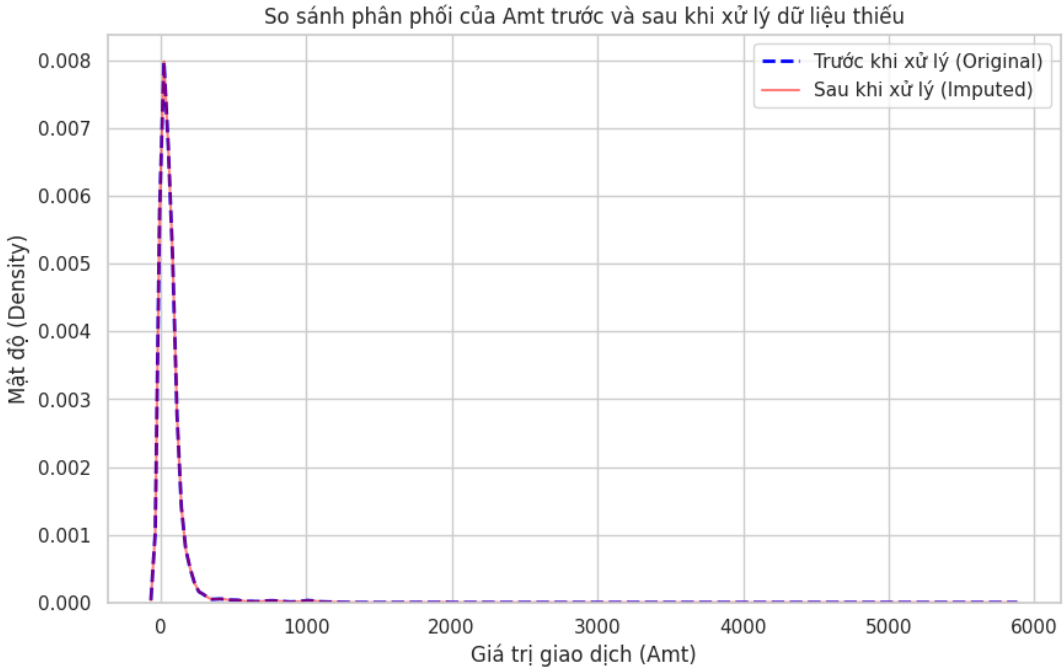

Hình 6: Biểu đồ mật độ (KDE Plot) so sánh dữ liệu trước và sau khi xử lý

Dựa trên kết quả thực nghiệm tại Hình 6, nhóm rút ra các nhận xét sau:

- **So sánh:** Biểu đồ mật độ (KDE Plot) cho thấy đường phân phối trước và sau khi xử lý trùng khớp hoàn toàn. Kết quả này phản ánh tính chất thực tế của tập dữ liệu *Credit Card Fraud*, khi mà dữ

liệu gốc đã ở trạng thái đầy đủ (không chứa giá trị `NaN`), do đó quy trình lấp đầy không làm thay đổi cấu trúc phân phối.

- **Đánh giá:** Quy trình điền dữ liệu đã thực hiện thành công việc duy trì các đặc trưng thống kê cốt lõi (như trung bình, phương sai) của tập dữ liệu gốc. Điều này cực kỳ quan trọng trong việc xây dựng Pipeline tiền xử lý, giúp đảm bảo tính ổn định và duy trì độ tin cậy cho các bước huấn luyện mô hình học máy tiếp theo.

2.3 Chuẩn hóa dữ liệu (Data Normalization)

2.3.1 Kỹ thuật thực hiện

Nhóm thực hiện chuẩn hóa đặc trưng `amt` (số tiền giao dịch) để đưa dữ liệu về cùng một thang đo bằng ba phương pháp phổ biến từ thư viện `Scikit-learn`:

- **Min-Max Scaling:** Chuyển dữ liệu về đoạn $[0, 1]$ dựa trên giá trị cực tiểu và cực đại của tập dữ liệu.
- **Standardization (Z-score):** Biến đổi dữ liệu để có trung bình bằng 0 và độ lệch chuẩn bằng 1.
- **Robust Scaling:** Sử dụng Trung vị (Median) và Khoảng tứ phân vị (IQR) để chuẩn hóa, giúp hạn chế ảnh hưởng của các giá trị ngoại lai.

2.3.2 Lý do và Mục tiêu

Trong tập dữ liệu giao dịch này, cột `amt` có biên độ dao động rất lớn (từ gần 0 đến hơn 4,000 đơn vị). Nếu không chuẩn hóa, các thuật toán dựa trên khoảng cách (như KNN, SVM) hoặc các thuật toán tối ưu hóa sẽ bị biến này chi phối hoàn toàn. Việc chuẩn hóa giúp cân bằng tầm quan trọng của các thuộc tính và tăng tốc độ hội tụ cho mô hình.

2.3.3 Kết quả trực quan và Phân tích so sánh

Dựa trên kết quả thực nghiệm trực quan hóa qua biểu đồ Histogram và Boxplot (Hình 4 và Hình 5), nhóm đưa ra các phân tích chi tiết về tác động của từng phương pháp:

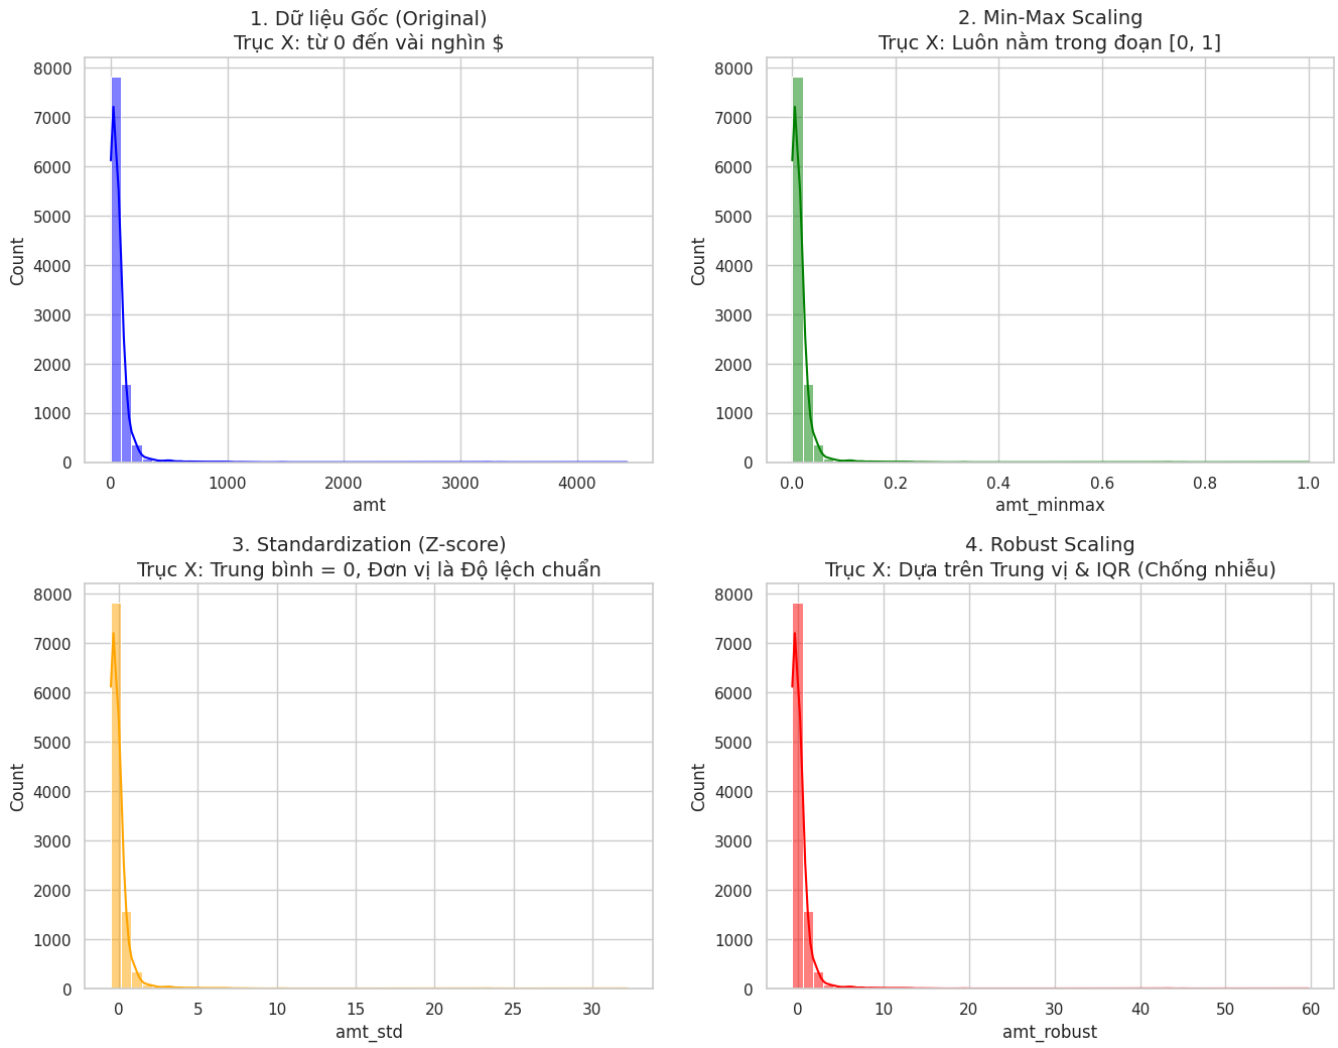

Hình 7: So sánh phân phối dữ liệu qua các kỹ thuật chuẩn hóa khác nhau

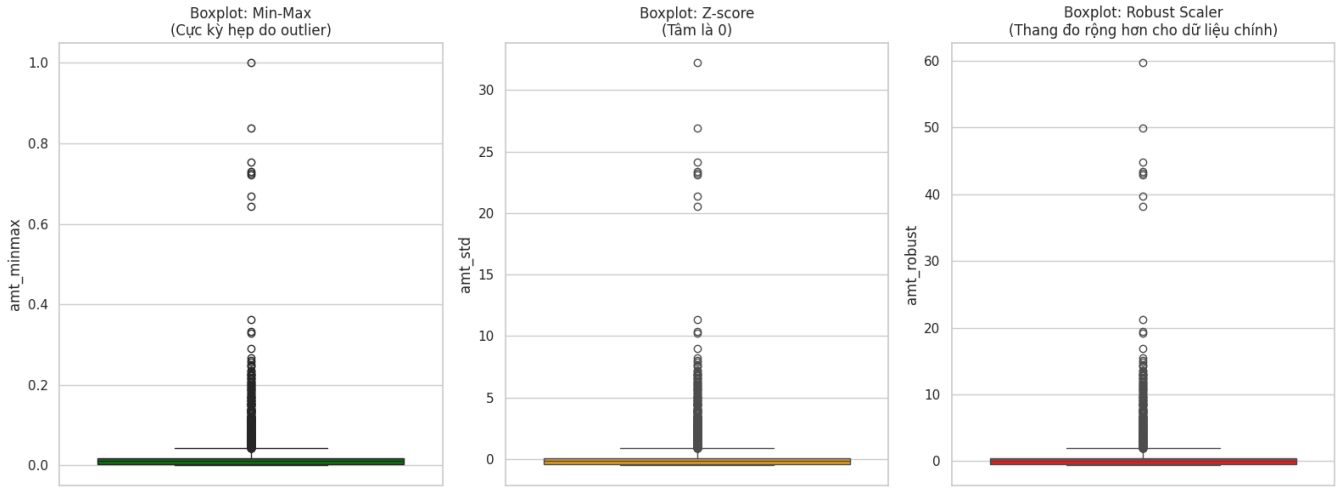

Hình 8: Trực quan hóa tác động của giá trị ngoại lai bằng biểu đồ Boxplot

Đặc điểm dữ liệu gốc (Original Data): Biểu đồ Histogram đầu tiên cho thấy phân phối `amt` bị lệch phải cực kỳ nặng. Phần lớn giao dịch tập trung ở mức dưới 500$, nhưng xuất hiện các giá trị ngoại lai (outliers) kéo dài đến hơn 4,000$. Sự chênh lệch này khiến dữ liệu không tuân theo phân phối chuẩn.

Phân tích phương pháp Min-Max Scaling: Phương pháp này ép toàn bộ dữ liệu vào khoảng $[0, 1]$. Tuy nhiên, do có các giao dịch cực lớn (outlier tại mức 4,000$), toàn bộ phần dữ liệu tập trung (các giao dịch bình thường) bị nén chặt lại sát mức 0 (thể hiện rõ ở biểu đồ Boxplot khi thân hộp gần như là một đường thẳng). Điều này làm mất đi sự khác biệt nhỏ giữa các giao dịch thông thường, gây khó khăn cho việc học máy.

Phân tích phương pháp Standardization (Z-score): Phương pháp này đưa trung bình về 0. Qua biểu đồ, ta thấy các giá trị ngoại lai nằm ở mức vượt quá 30 lần độ lệch chuẩn. Mặc dù dữ liệu đã được căn chỉnh, nhưng vì giá trị trung bình và độ lệch chuẩn rất nhạy cảm với các con số cực đoan, thang đo vẫn bị kéo giãn mạnh về phía các giá trị ngoại lai, làm phân phối chính vẫn bị dồn cục ở phía trái trục tung.

Phân tích phương pháp Robust Scaling: Đây là phương pháp mang lại kết quả khả quan nhất đối với tập dữ liệu này. Thang đo của Robust Scaling trải rộng từ mức dưới 0 đến hơn 60 đơn vị IQR. Vì sử dụng Trung vị và IQR (các thông số thống kê bền vững), phương pháp này không bị các giao dịch 4,000$ làm chệch hướng trung tâm. Biểu đồ Boxplot cho thấy "thân hộp" (chứa 50% dữ liệu chính) có không gian biểu diễn rộng hơn, giúp giữ lại cấu trúc nguyên thủy của dữ liệu quan trọng mà không bị biến dạng bởi nhiễu.

2.3.4 So sánh và Kết luận

Bảng 2: So sánh các phương pháp chuẩn hóa đối với đặc trưng `amt`

Phương pháp	**Ưu điểm**	**Nhược điểm**
Min-Max Scaling	Giới hạn dữ liệu trong khoảng cố định $[0, 1]$, phù hợp cho Neural Networks.	Rất nhạy cảm với outlier; nén dữ liệu chính khiến mất mát thông tin.
Z-score	Cân bằng dữ liệu quanh điểm 0, phù hợp cho các mô hình giả định phân phối chuẩn.	Vẫn bị ảnh hưởng bởi outlier do trung bình và độ lệch chuẩn bị kéo lệch.
Robust Scaling	**Cực kỳ hiệu quả với dữ liệu có nhiều outlier, giữ nguyên cấu trúc dữ liệu chính.**	Thang đo kết quả không cố định trong một khoảng hẹp như $[0, 1]$.

Kết luận: Đối với bài toán phát hiện gian lận thẻ tín dụng, nơi các giao dịch gian lận thường là các điểm ngoại lai giá trị cao, phương pháp **Robust Scaling** được lựa chọn là phương pháp chuẩn hóa tối ưu nhất. Nó giúp mô hình duy trì được độ nhạy đối với các giao dịch nhỏ trong khi vẫn giữ lại thông tin quan trọng từ các giao dịch có giá trị bất thường.

2.4 Mã hóa biến phân loại (Categorical Encoding)

2.4.1 Xác định biến phân loại

Trong bước này, nhóm tiến hành phân tích độ đa dạng (cardinality) của các biến phân loại để lựa chọn kỹ thuật mã hóa tối ưu, tránh làm bùng nổ chiều dữ liệu:

- **Biến Nominal ít nhóm:** `gender` (chỉ bao gồm 2 giá trị: M, F).
- **Biến High-cardinality (Độ đa dạng cao):** `merchant` với **692** giá trị duy nhất và `category` với **14** nhóm ngành hàng.

2.4.2 Chi tiết triển khai và Thảo luận

Nhóm đã triển khai phối hợp ba kỹ thuật mã hóa để chuyển đổi các thuộc tính định danh sang định dạng số mà mô hình máy học có thể tiếp nhận:

Mã hóa One-Hot (One-Hot Encoding) Áp dụng cho biến `gender`. Sử dụng hàm `pd.get_dummies`, nhóm đã tạo ra hai cột nhị phân mới là `gen_F` và `gen_M`. Kỹ thuật này đảm bảo tính khách quan cho mô hình vì giới tính không có thứ tự ưu tiên, tránh việc mô hình gán các trọng số sai lệch nếu sử dụng mã hóa số nguyên đơn giản.

Mã hóa Tần suất (Frequency Encoding) Áp dụng cho biến `merchant`. Do có tới 692 người bán khác nhau, việc sử dụng One-Hot Encoding sẽ tạo ra quá nhiều cột. Thay vào đó, nhóm thay thế tên người bán bằng tỷ lệ xuất hiện của họ trong tập dữ liệu (cột `merchant_freq_enc`).

- *Ví dụ:* Người bán `fraud_Towne LLC` có giá trị mã hóa là **0.0017** (tương ứng chiếm 0.17% tổng số giao dịch).

Cách tiếp cận này giúp giữ lại thông tin về quy mô và mức độ phổ biến của người bán chỉ trong một cột duy nhất.

Mã hóa Mục tiêu (Target Encoding) Áp dụng cho biến `category`. Nhóm thay thế mỗi danh mục chi tiêu bằng giá trị trung bình của biến mục tiêu `is_fraud` tương ứng với danh mục đó.

- *Phân tích kết quả:* Danh mục `misc_pos` có giá trị mã hóa là **0.003215**, trong khi danh mục `health_fitness` có giá trị **0.000000** (cho thấy trong tập mẫu này, ngành hàng sức khỏe chưa ghi nhận giao dịch gian lận).

Kỹ thuật này cực kỳ hiệu quả trong bài toán Fraud Detection vì nó trực tiếp cung cấp thông tin về "mức độ rủi ro gian lận" của từng loại hình dịch vụ cho mô hình.

Bảng 3: Minh họa kết quả mã hóa các biến quan trọng (5 dòng đầu)

Merchant (Gốc)	**Freq_Enc**	**Category (Gốc)**	**Target_Enc**
fraud_Towne LLC	0.0017	misc_pos	0.003215
fraud_Friesen Ltd	0.0012	health_fitness	0.000000
fraud_Mohr Inc	0.0021	shopping_pos	0.009730
fraud_Gaylord-Powlowski	0.0018	home	0.002055
fraud_Christiansen...	0.0022	gas_transport	0.007744

Thảo luận: Sau khi tiền xử lý, danh sách thuộc tính đã được mở rộng với các cột mã hóa mới (như hiển thị trong Hình ...), giúp mô hình tập trung vào các đặc trưng có giá trị dự báo cao như tần suất giao dịch và tỷ lệ rủi ro ngành hàng thay vì các nhãn chữ thuần túy.

2.5 Lựa chọn đặc trưng (Feature Selection)

2.5.1 Phương pháp sử dụng

Sau các bước chuẩn hóa và mã hóa, tập dữ liệu tồn tại sự dư thừa thông tin đáng kể, đặc biệt là giữa các biến số tiền và tọa độ địa lý. Nhóm thực hiện quy trình lựa chọn đặc trưng qua 3 công đoạn chính để tối ưu hóa không gian đặc trưng:

1. **Phân tích đa cộng tuyến (Correlation Matrix):** Nhóm tiến hành đo lường hệ số tương quan Pearson giữa các biến số. Kết quả thực nghiệm cho thấy các đặc trưng `amt`, `amt_minmax`, và `amt_std` tương quan tuyệt đối ($\rho = 1.0$) với `amt_robust`. Nhóm quyết định loại bỏ 3 đặc trưng dư thừa này. Đồng thời, ma trận tương quan (Hình 9) cho thấy sự tương quan cực cao ($0.99 - 1.0$) giữa tọa độ khách hàng (`lat, long`) và tọa độ cửa hàng (`merch_lat, merch_long`), do đó nhóm ưu tiên giữ lại tọa độ cửa hàng để giảm nhiễu.

2. **Đánh giá độ quan trọng đặc trưng (Feature Importance):** Sử dụng mô hình Random Forest để xếp hạng khả năng đóng góp của từng biến vào việc phân tách nhãn gian lận.

3. **Loại bỏ đặc trưng đệ quy (RFE):** Phối hợp với mô hình cây để tự động loại bỏ các biến kém hiệu quả nhất và giữ lại 5 đặc trưng tối ưu.

2.5.2 Kết quả thực nghiệm và Giải thích

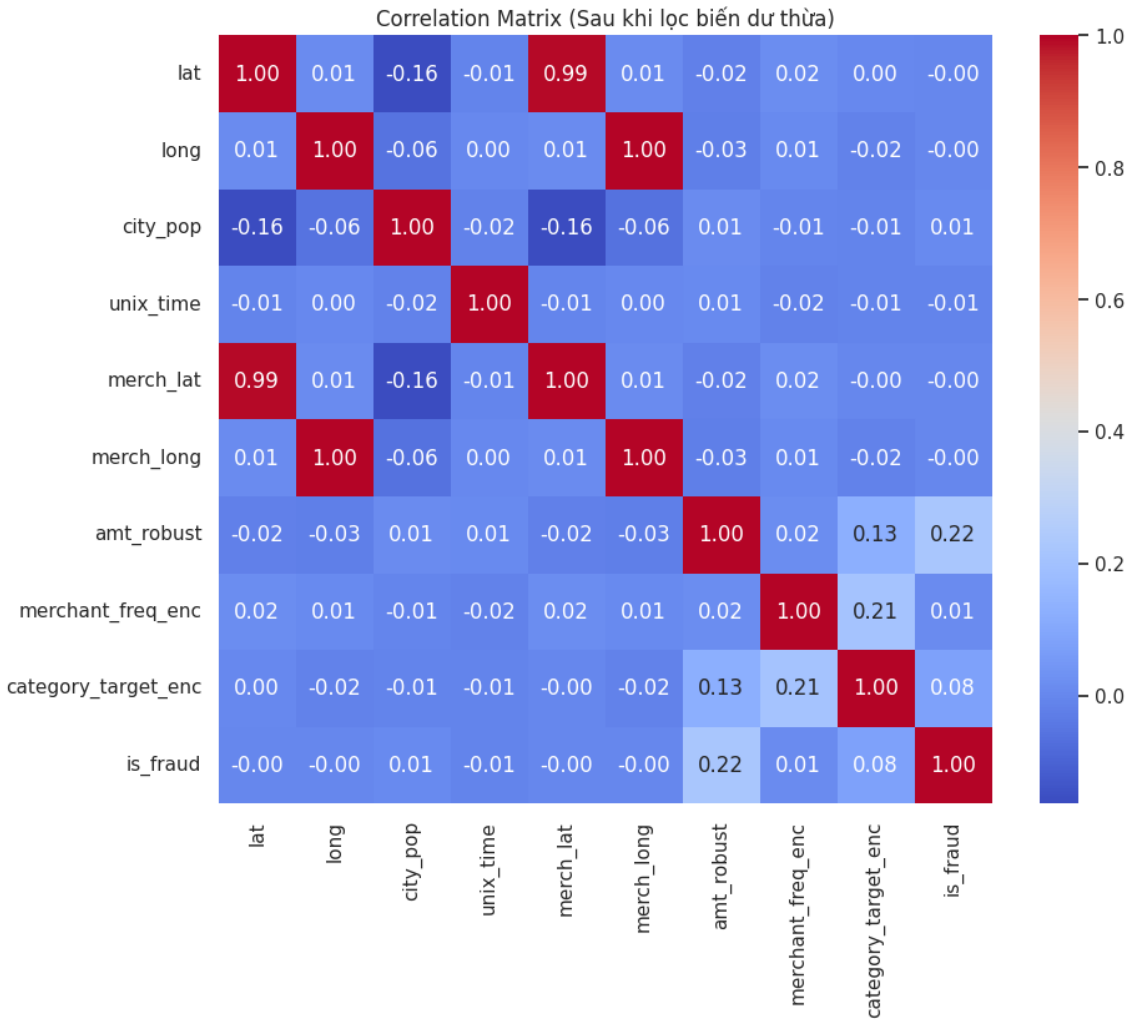

Hình 9: Ma trận tương quan sau khi loại bỏ các đặc trưng đa cộng tuyến

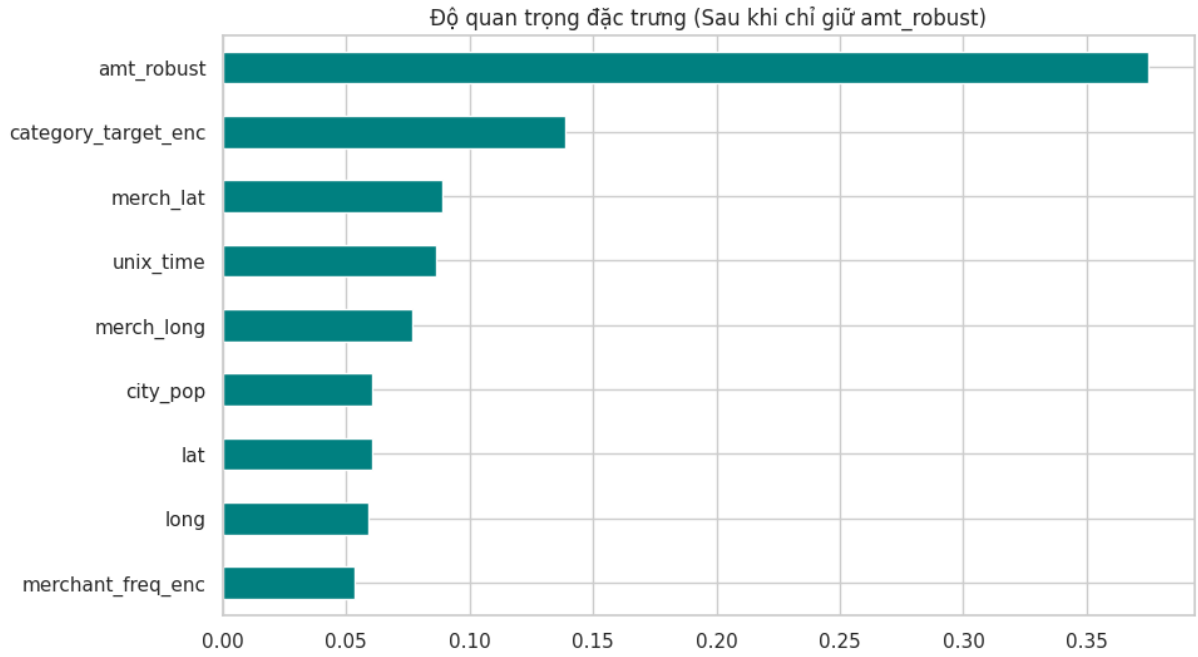

Hình 10: Xếp hạng độ quan trọng đặc trưng sau khi tập trung tín hiệu

Phân tích kết quả thực nghiệm:

- **Sự thống trị của giá trị giao dịch:** Sau khi dồn tín hiệu từ các biến tiền dư thừa, đặc trưng `amt_robust` thể hiện sức mạnh dự báo áp đảo với độ quan trọng đạt xấp xỉ **37%**. Điều này khẳng định quy mô tài chính là dấu hiệu quan trọng nhất để nhận diện giao dịch bất thường.
- **Tín hiệu từ hành vi và vị trí:** Đặc trưng `category_target_enc` (mã hóa mục tiêu theo danh mục) đứng vị trí thứ hai với tỉ lệ **14%**, cho thấy rủi ro đặc thù của từng ngành hàng là thông tin then chốt. Tiếp theo là các đặc trưng về tọa độ cửa hàng (`merch_lat`) và thời gian (`unix_time`).
- **Tập đặc trưng tối ưu:** Thuật toán RFE đã lựa chọn chính xác 5 đặc trưng mang lại độ chính xác cao nhất cho mô hình: `amt_robust`, `category_target_enc`, `merch_lat`, `unix_time`, và `merch_long`.

2.5.3 Kết luận cuối cùng

Tập đặc trưng được lựa chọn cuối cùng đã loại bỏ thành công hiện tượng đa cộng tuyến, giúp mô hình tập trung vào các thông số mang tính phân tách cao. Tập 5 đặc trưng này bao phủ trọn vẹn 4 khía cạnh cốt lõi của một giao dịch:

- **Giá trị:** `amt_robust` (Quy mô giao dịch).
- **Hành vi:** `category_target_enc` (Loại hình dịch vụ rủi ro).

- **Vị trí:** `merch_lat, merch_long` (Địa điểm giao dịch).
- **Thời gian:** `unix_time` (Thời điểm giao dịch).

Đây sẽ là dữ liệu đầu vào chuẩn hóa để nhóm tiến hành xây dựng các mô hình phân loại ở giai đoạn tiếp theo.

3 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN (TEXTUAL DATA) - BONUS

3.1 Lựa chọn tập dữ liệu (Dataset Selection)

- **Nguồn gốc:** Tập dữ liệu được lấy từ Kaggle: IMDB Dataset of 50K Movie Reviews.
- **Đặc điểm dữ liệu:** Tập dữ liệu gốc bao gồm 50,000 bản ghi. Để tối ưu hóa thời gian thực hiện tiền xử lý, nhóm đã trích xuất ngẫu nhiên một tập mẫu (sample) gồm 2,000 dòng.
- **Sự phân bổ nhãn:** Như thể hiện trong Hình 11, tập dữ liệu mẫu có sự cân bằng cao về mặt sắc thái cảm xúc với **976** đánh giá tích cực (`positive`) và **1,024** đánh giá tiêu cực (`negative`). Điều này giúp đảm bảo mô hình không bị bias trong quá trình huấn luyện.
- **Mô tả tóm tắt:** Dữ liệu văn bản thô chứa nhiều nhiễu bao gồm các thẻ HTML (như `<br />`), ký tự đặc biệt, dấu câu và các hư từ (stop words).
- **Trường hợp sử dụng:** Phân tích cảm xúc (Sentiment Analysis) để tự động phân loại đánh giá của người dùng về phim ảnh.

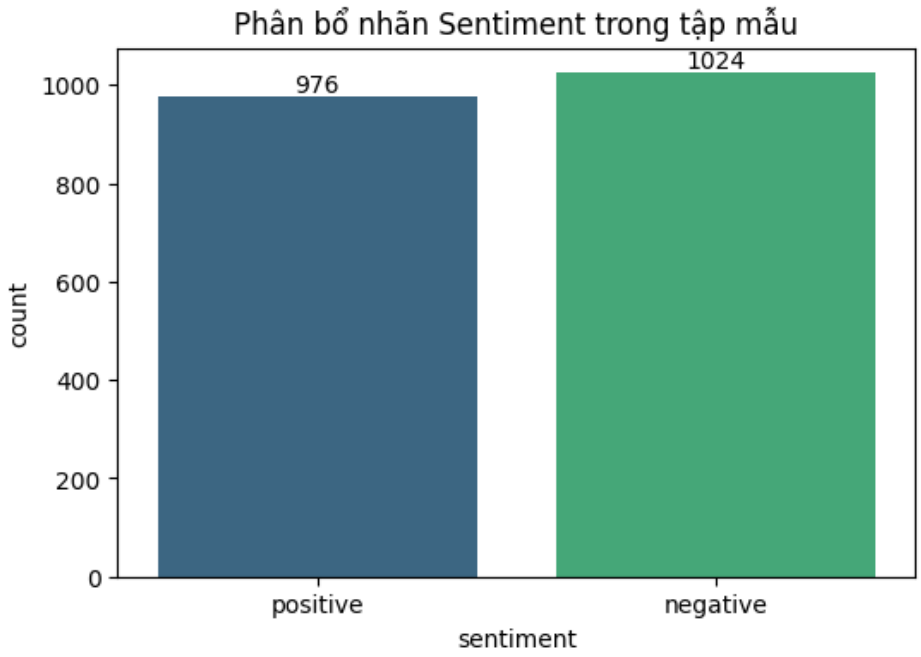

Hình 11: Phân bổ nhãn cảm xúc trong tập dữ liệu mẫu (2,000 dòng)

3.2 Tách từ (Tokenization)

Tokenization là bước khởi đầu quan trọng trong quy trình tiền xử lý, nhằm phân rã các chuỗi văn bản dài thành các đơn vị nhỏ hơn gọi là "tokens" (từ, cụm từ, hoặc ký tự). Nhóm đã thực hiện thực nghiệm trên một đoạn văn bản mẫu từ tập dữ liệu (sau khi đã làm sạch các thẻ HTML):

> *"I really liked this Summerslam due to the look of the arena, the curtains and just the look overall was interesting to me for some reason. Anyways, this could have been one of the best Summerslam's ev..."*

3.2.1 Triển khai các kỹ thuật thực hiện

- **Word Tokenization (Tách theo từ):** Sử dụng thư viện `nltk.word_tokenize`. Phương pháp này tách văn bản dựa trên khoảng trắng và các dấu câu.
  - *Ví dụ 5 token đầu tiên:* `['I', 'really', 'liked', 'this', 'Summerslam']`
- **Sentence Tokenization (Tách theo câu):** Sử dụng `nltk.sent_tokenize`. Kỹ thuật này phân chia văn bản thành các câu hoàn chỉnh dựa trên các dấu kết thúc câu.
- **Subword Tokenization (Tách theo từ phụ):** Sử dụng `BertTokenizer` (`bert-base-uncased`). Phương pháp này chia nhỏ các từ phức tạp hoặc từ hiếm thành các đơn vị nhỏ hơn để tránh lỗi từ

ngoài từ điển (OOV).

- *Ví dụ 5 token đầu tiên:* `['i', 'really', 'liked', 'this', 'summers']` (Lưu ý: Từ gốc "Summerslam" đã bị chia nhỏ thành "summers" và "##lam").

3.2.2 So sánh các chiến lược tách từ

Dựa trên kết quả chạy code trên đoạn review mẫu, các thông số định lượng thu được như sau:

Phương pháp	**Số lượng Tokens**	**Đặc điểm nhận diện**
Sentence Tokenization	5	Phân tách theo cấu trúc câu.
Word Tokenization	221	Giữ nguyên các từ vựng và dấu câu.
Subword Tokenization	261	Chia nhỏ từ phức thành các mảnh gốc (subwords).

Bảng 4: So sánh định lượng các phương pháp Tokenization trên mẫu dữ liệu thực tế

3.2.3 Thảo luận và Ưu điểm đối với tập dữ liệu IMDB

1. **Word Tokenization:**
   - *Ưu điểm:* Đơn giản, giữ nguyên được ý nghĩa của hầu hết các từ vựng thông dụng trong các review phim.
   - *Hạn chế:* Đối với các từ đặc thù như "Summerslam", nếu không có trong từ điển, mô hình sẽ gặp khó khăn khi xử lý ý nghĩa.
2. **Subword Tokenization (Lựa chọn tối ưu):**
   - *Ưu điểm vượt trội:* Như đã thấy ở ví dụ trên, từ **"Summerslam"** được tách thành **"summers"** và mảnh hậu tố. Điều này giúp mô hình vẫn nhận biết được các thành phần mang ý nghĩa gốc của từ.
   - *Cơ chế:* Bằng cách tăng số lượng token lên (từ 221 lên 261), Subword Tokenization giúp bao phủ được cả các lỗi chính tả, từ ghép hoặc các tên riêng thường gặp trong đánh giá phim mà không làm bùng nổ kích thước từ điển. Đây là tiền đề quan trọng để đưa dữ liệu vào các mô hình Transformer hiện đại.

3.3 Loại bỏ từ dừng (Removing Stop Words)

Trong tập dữ liệu văn bản, "từ dừng" (stop words) là những từ xuất hiện với tần suất rất cao nhưng mang lại ít giá trị ngữ nghĩa trong việc phân loại cảm xúc. Việc xử lý stop words là bước tối quan trọng để giảm nhiễu và tập trung vào các từ mang giá trị nội dung (content words).

3.3.1 Nhận diện các từ dừng phổ biến trong tập dữ liệu

Thông qua việc thống kê tần suất xuất hiện của các từ trước khi tiền xử lý (Hình 2), nhóm xác định được các từ dừng chiếm ưu thế tuyệt đối trong tập dữ liệu IMDB. Các từ như *'the', 'and', 'a', 'of', 'to', 'is'* xuất hiện hàng chục nghìn lần nhưng không đóng góp vào việc phân loại `positive` hay `negative`.

Đặc biệt, mã nguồn cho thấy sự tồn tại của token *'br'*. Đây là kết quả của các thẻ HTML `<br />` trong dữ liệu thô chưa được làm sạch triệt để ở bước tách từ sơ khai. Nếu không loại bỏ các token này, mô hình sẽ bị lãng phí tài nguyên tính toán vào các đặc trưng vô nghĩa.

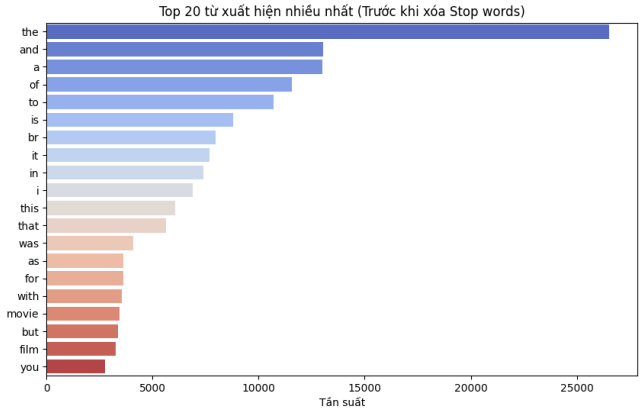

Hình 12: Top 20 từ trước khi xử lý (Chủ yếu là hư từ)

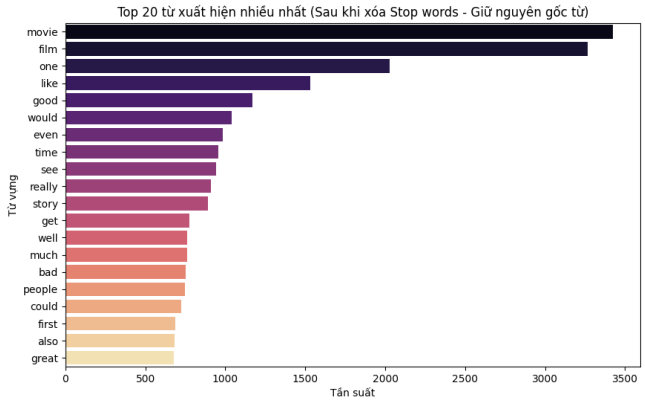

Hình 13: Top 20 từ sau khi xóa Stop words (Từ mang ý nghĩa nội dung)

3.3.2 Thực nghiệm loại bỏ và tác động đến kích thước dữ liệu

Nhóm đã triển khai hàm `clean_only_stopwords` để loại bỏ các từ dừng tiêu chuẩn từ thư viện `nltk`, đồng thời loại bỏ các ký tự không phải chữ cái thông qua phương thức `isalpha()`. Kết quả định lượng trên 2,000 mẫu dữ liệu cho thấy sự thay đổi rõ rệt:

Chỉ số	**Trước khi loại bỏ**	**Sau khi loại bỏ**	**Tỷ lệ giảm**
Tổng số lượng Tokens	446,273	226,487	**49.25%**
Kích thước từ điển (Vocab size)	24,500	24,360	**0.57%**

Bảng 5: Tác động của việc loại bỏ Stop Words đến kích thước dữ liệu

3.3.3 Phân tích tác động và khả năng giữ lại thông tin

Việc loại bỏ stop words mang lại những thay đổi tích cực về mặt đặc trưng dữ liệu:

- **Sự dịch chuyển đặc trưng:** Quan sát Hình 12, danh sách các từ phổ biến nhất đã thay đổi hoàn toàn từ các hư từ sang các từ mang đậm nội dung điện ảnh như *'movie', 'film', 'one', 'like', 'good', 'story'*. Điều này chứng tỏ thông tin cốt lõi của đánh giá đã được giữ lại và làm nổi bật hơn.

- **Hiệu quả nén dữ liệu:** Mặc dù tổng số lượng tokens giảm gần một nửa (**49.25%**), nhưng kích thước từ điển (Vocab size) chỉ giảm cực nhẹ (**0.57%**). Điều này xác nhận rằng stop words là các từ có tính lặp lại cực cao; việc loại bỏ chúng giúp loại bỏ sự dư thừa về mặt thống kê mà không làm mất đi sự phong phú của vốn từ vựng duy nhất.
- **Tối ưu hóa không gian vector:** Việc giảm 50% số lượng tokens giúp các mô hình vector hóa (như TF-IDF hoặc BoW) giảm bớt độ thưa (sparsity) không cần thiết, giúp mô hình tập trung trọng số vào các từ có khả năng phân biệt cảm xúc cao.
- **Bảo toàn ngữ cảnh phủ định:** Trong bước tiền xử lý tổng hợp phía sau, nhóm lưu ý giữ lại các từ như *'not', 'no', 'but'*. Mặc dù chúng nằm trong danh sách stop words tiêu chuẩn, nhưng việc giữ lại chúng là cần thiết để bảo toàn thông tin logic trong câu (ví dụ: *"not good"* khác hoàn toàn *"good"*).

3.4 Gốc từ và Chuẩn hóa từ (Stemming and Lemmatization)

Sau bước tách từ và loại bỏ từ dừng, các từ vẫn có thể tồn tại ở nhiều dạng biến thể (số ít/số nhiều, các thì của động từ). Nhóm đã thực hiện kỹ thuật "chuẩn hóa văn bản" để đưa các biến thể này về một dạng gốc duy nhất, giúp giảm chiều không gian đặc trưng và tăng cường khả năng nhận diện mẫu của mô hình.

3.4.1 Triển khai thực nghiệm các thuật toán

Nhóm đã so sánh ba phương pháp phổ biến nhất trong thư viện `nltk`:

- **Porter Stemmer:** Thuật toán cắt bỏ hậu tố dựa trên tập quy tắc cứng (heuristic).
- **Snowball Stemmer:** Một phiên bản cải tiến của Porter, có tốc độ xử lý nhanh và độ chính xác cao hơn đối với tiếng Anh.
- **WordNet Lemmatizer:** Kỹ thuật chuẩn hóa dựa trên từ điển và phân tích hình thái học, đưa từ về "nguyên mẫu" (lemma) có nghĩa.

3.4.2 So sánh kết quả thực nghiệm

Kết quả chuẩn hóa trên một câu mẫu trích từ tập dữ liệu được trình bày trong bảng dưới đây:

Từ gốc (Original)	**Porter Stemmer**	**Snowball**	**Lemmatization (v)**
were	were	were	**be**
amazing	amaz	amaz	amaze
stories	stori	stori	stories
told	told	told	**tell**
beautifully	beauti	beauti	beautifully
movies	movi	movi	movies

Bảng 6: Bảng so sánh kết quả giữa Stemming và Lemmatization

3.4.3 Thảo luận về ưu điểm và nhược điểm đối với tập dữ liệu IMDB

Dựa trên đặc thù của bài toán phân tích cảm xúc phim ảnh, nhóm đưa ra các nhận định sau:

1. **Kỹ thuật Stemming (Porter/Snowball):**
   - *Ưu điểm:* Tốc độ xử lý cực nhanh, giúp giảm đáng kể số lượng từ vựng duy nhất (Vocabulary size). Ví dụ: 'amazing', 'amazed', 'amaze' đều được đưa về 'amaz', giúp mô hình tập trung vào gốc nghĩa của từ.
   - *Nhược điểm:* Tạo ra các từ không có nghĩa (như 'stori', 'beauti', 'movi'), điều này có thể làm mất đi sắc thái biểu cảm tinh tế (như sự khác biệt giữa trạng từ 'beautifully' và tính từ 'beautiful').
2. **Kỹ thuật Lemmatization:**
   - *Ưu điểm:* Giữ được ý nghĩa ngôn ngữ học chính xác. Việc đưa 'were' về 'be' hay 'told' về 'tell' (khi sử dụng `pos='v'`) giúp mô hình hiểu được bản chất của hành động mà không bị nhiễu bởi các thì của động từ. Điều này cực kỳ quan trọng đối với các mô hình ngôn ngữ hiện đại hoặc khi cần giải thích mô hình (Explainable AI).
   - *Nhược điểm:* Tốn tài nguyên tính toán hơn và phụ thuộc vào việc gán nhãn từ loại (POS tagging). Nếu không xác định đúng từ loại, Lemmatizer có thể không thay đổi được từ gốc (ví dụ: 'stories' vẫn giữ là 'stories' thay vì 'story').

Kết luận cho tập dữ liệu: Đối với bài toán phân tích cảm xúc trên IMDB, **Lemmatization** được ưu tiên hơn vì tính chính xác về ngữ nghĩa. Tuy nhiên, nếu ưu tiên huấn luyện nhanh trên tập dữ liệu lớn 50,000 dòng, Snowball Stemmer là một lựa chọn thay thế chấp nhận được nhờ khả năng gom nhóm các biến thể từ rất mạnh mẽ.

3.5 Vector hóa văn bản (Text Vectorization)

Sau khi dữ liệu đã được làm sạch và chuẩn hóa (xóa HTML, loại bỏ stop-words và Lemmatization), bước cuối cùng là chuyển đổi văn bản từ dạng ký tự sang dạng số (vector) để các thuật toán học máy có thể xử lý. Nhóm đã thực hiện thực nghiệm và so sánh ba phương pháp biểu diễn dữ liệu khác nhau.

3.5.1 Các kỹ thuật thực hiện

- **Bag-of-Words (BoW):** Sử dụng `CountVectorizer` với tham số `max_features=5000`. Phương pháp này đếm tần suất xuất hiện của 5,000 từ phổ biến nhất trong tập dữ liệu. Mỗi review được đại diện bởi một vector có độ dài 5,000, trong đó mỗi phần tử tương ứng với số lần xuất hiện của một từ.
- **TF-IDF (Term Frequency-Inverse Document Frequency):** Sử dụng `TfidfVectorizer` cũng với giới hạn 5,000 đặc trưng (`max_features=5000`). Kỹ thuật này gán trọng số cho từ dựa trên tần suất xuất hiện trong review và độ hiếm của chúng trên toàn bộ tập dữ liệu, giúp làm nổi bật các từ mang tính đặc trưng cao.
- **Word Embeddings (Word2Vec):** Sử dụng mô hình `Word2Vec` từ thư viện `gensim` với kích thước vector (`vector_size`) cố định là 100. Nhóm đã xây dựng Document Vector bằng cách tính trung bình cộng vector của tất cả các từ trong một review (Average Word2Vec), giúp nắm bắt mối quan hệ ngữ nghĩa giữa các từ.

3.5.2 So sánh về số chiều và độ thưa (Dimensionality and Sparsity)

Dựa trên kết quả thực thi trên 2,000 mẫu review đã qua xử lý, các đặc tính của ma trận đặc trưng được thống kê như sau:

Phương pháp	**Kích thước (Shape)**	**Số chiều (Dim)**	**Độ thưa (Sparsity)**
Bag-of-Words (BoW)	(2000, 5000)	5,000	**98.41%**
TF-IDF	(2000, 5000)	5,000	**98.41%**
Word2Vec (Embedding)	(2000, 100)	**100**	**0.00%**

Bảng 7: So sánh đặc tính các phương pháp vector hóa văn bản theo thực nghiệm

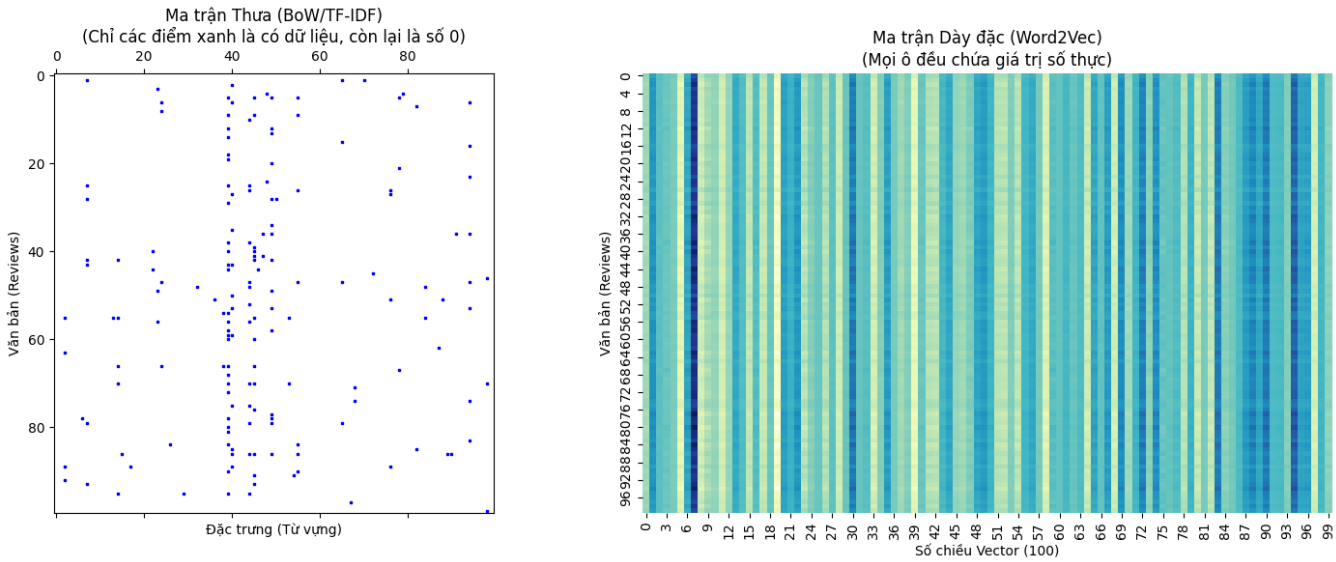

Hình 14: Trực quan hóa sự khác biệt giữa cấu trúc ma trận thưa (BoW/TF-IDF) và ma trận dày đặc (Word2Vec)

3.5.3 Phân tích và Thảo luận

Từ bảng số liệu và hình ảnh trực quan hóa (Hình 14), nhóm đưa ra các nhận định sau:

1. **Về số chiều (Dimensionality):**
   - Mặc dù từ điển ban đầu có hơn 20,000 từ, nhóm đã giới hạn BoW và TF-IDF ở mức **5,000 chiều** để tối ưu hóa hiệu suất. Tuy nhiên, số chiều này vẫn gấp 50 lần so với Word2Vec.
   - Word2Vec nén thông tin cực tốt vào **100 chiều cố định**, giúp tránh được "lời nguyền đa chiều" và giảm tải cho tài nguyên hệ thống (RAM/CPU) khi huấn luyện các mô hình phức tạp.
2. **Về độ thưa (Sparsity):**
   - Ma trận BoW và TF-IDF cực kỳ thưa thớt (**98.41%**). Hình 14 (bên trái) cho thấy phần lớn các ô trong ma trận là số 0 (màu trắng), vì một review phim thông thường chỉ sử dụng một lượng rất nhỏ từ vựng so với từ điển 5,000 từ.
   - Ngược lại, ma trận Word2Vec là ma trận dày đặc (Sparsity **0.00%**). Hình 14 (bên phải) đặc kín các giá trị số thực (màu sắc phân bổ đều), chứng tỏ mọi chiều trong vector đều mang thông tin hữu ích.
3. **Về khả năng biểu diễn ngữ nghĩa:**
   - BoW/TF-IDF chỉ quan tâm đến tần suất từ đơn lẻ.

- Word2Vec (với tham số `window=5`) cho phép mô hình học được ngữ cảnh. Điều này giúp các review có các từ đồng nghĩa (ví dụ: "amazing" và "breathtaking") có biểu diễn vector gần nhau, tăng độ chính xác cho bài toán phân loại cảm xúc.

Kết luận: Qua thực nghiệm, **Word2Vec** cho thấy sự ưu việt về khả năng nén dữ liệu và biểu diễn ngữ nghĩa dày đặc, trong khi **TF-IDF** vẫn là một phương pháp mạnh mẽ và dễ giải thích cho các mô hình học máy cơ bản trên tập dữ liệu đánh giá phim.

4 TIỀN XỬ LÝ DỮ LIỆU THỜI GIAN (TEMPORAL DATA) - BONUS

4.1 Lựa chọn tập dữ liệu (Dataset Selection)

- **Tên tập dữ liệu:** COVID-19 Time Series Data (Dữ liệu chuỗi thời gian COVID-19 toàn cầu).
- **Nguồn gốc:** Được tổng hợp và chia sẻ bởi Niket Chauhan trên nền tảng Kaggle. *Link:* https://www.kaggle.com/datasets/niketchauhan/covid-19-time-series-data
- **Quy mô và đặc điểm:**
  - Bao gồm dữ liệu của nhiều quốc gia và vùng lãnh thổ trên thế giới, với số lượng bản ghi lớn và cập nhật liên tục.
  - Ghi nhận 3 chỉ số chính: *Confirmed*, *Deaths*, và *Recovered*.
  - Dữ liệu được ghi nhận theo tần suất **hàng ngày (daily)**, là dạng quan sát đều (regular time interval), phù hợp cho phân tích xu hướng và dự báo.

4.2 Xử lý định dạng thời gian (Parsing Date and Time)

4.2.1 Kỹ thuật triển khai

- **Định dạng kiểu dữ liệu:** Nhóm sử dụng hàm `pd.to_datetime()` để chuyển đổi cột `Date` từ dạng chuỗi văn bản (*Object*) sang định dạng chuẩn `datetime64[ns]`. Tham số `errors='coerce'` được thiết lập để đảm bảo tính an toàn, tự động xử lý các giá trị sai định dạng nếu có.
- **Kiểm tra tính toàn vẹn:** Ngay sau khi chuyển đổi, nhóm thực hiện kiểm tra số lượng giá trị `NaT` (Not a Time). Việc xác nhận không có lỗi phát sinh trong quá trình *Parsing* là điều kiện bắt buộc để đảm bảo tính chính xác cho toàn bộ quy trình tính toán chuỗi thời gian ở các bước sau.

- **Thiết lập cấu trúc chuỗi thời gian:** Nhóm chuyển đổi cột `Date` thành chỉ mục (*Datetime Index*) và áp dụng `sort_index()` để sắp xếp dữ liệu tăng dần theo thời gian. Bước này giúp biến một bảng dữ liệu phẳng thành một cấu trúc *Time-series DataFrame* chuyên dụng, tối ưu hóa tốc độ truy vấn và cắt lát dữ liệu.

4.2.2 Kết quả và phân tích dựa trên thực nghiệm

```
Thông tin kiểu dữ liệu của Index:
datetime64[ns]

5 dòng đầu tiên của DataFrame sau khi thiết lập Datetime Index:
```

	Country/Region	Province/State	Lat	Long	Confirmed	Recovered	Deaths
Date							
2020-01-22	Afghanistan	NaN	33.939110	67.709953	0	0.0	0
2020-01-22	Canada	Prince Edward Island	46.510700	-63.416800	0	NaN	0
2020-01-22	Seychelles	NaN	-4.679600	55.492000	0	0.0	0
2020-01-22	Canada	Ontario	51.253800	-85.323200	0	NaN	0
2020-01-22	Sierra Leone	NaN	8.460555	-11.779889	0	0.0	0

Hình 15: Cấu trúc DataFrame sau khi thiết lập Datetime Index.

Dựa trên kết quả thực thi và Hình 15, nhóm rút ra một số nhận xét chính như sau:

1. **Xác thực chuyển đổi kiểu dữ liệu:** Hệ thống hiển thị kiểu dữ liệu của Index là `datetime64[ns]`, cho thấy cột `Date` đã được chuyển đổi thành công từ kiểu chuỗi sang kiểu thời gian chuẩn. Điều này cho phép thực hiện các phép toán liên quan đến thời gian (tính số ngày, lọc theo mốc thời gian, v.v.) một cách chính xác và hiệu quả.

2. **Thiết lập cấu trúc chuỗi thời gian:** Sau khi đưa `Date` vào Index, DataFrame đã trở thành một cấu trúc chuỗi thời gian đúng nghĩa. Việc này giúp thao tác cắt lát theo ngày/tháng nhanh hơn và là nền tảng cần thiết cho các bước như Resampling và Rolling Window ở phần sau.

3. **Nhận diện dạng dữ liệu bảng:** Quan sát 5 dòng đầu tiên cho thấy cùng một ngày có thể xuất hiện ở nhiều quốc gia khác nhau. Điều này xác nhận bộ dữ liệu thuộc dạng **Panel Data**. Vì vậy, các thao tác như nội suy hoặc tạo đặc trưng trễ cần được thực hiện theo từng quốc gia thông qua `groupby` để tránh trộn lẫn dữ liệu giữa các thực thể.

4.2.3 Đánh giá chung về kỹ thuật

Việc xử lý và chuẩn hóa định dạng thời gian là bước tiền xử lý bắt buộc trong mọi bài toán chuỗi thời gian. Kỹ thuật này không làm thay đổi giá trị dữ liệu gốc, nhưng đóng vai trò nền tảng để đảm bảo tính chính xác cho các phép toán theo thời gian như nội suy (interpolation), tạo biến trễ (lag features), tính trung bình trượt (moving average) hay dự báo.

Nếu dữ liệu ban đầu đã ở định dạng `datetime` chuẩn và được sắp xếp đúng thứ tự, thì bước này có thể được giản lược. Ngược lại, với dữ liệu thực tế thường tồn tại sai định dạng, thiếu mốc thời gian hoặc không đồng nhất múi giờ, việc xử lý thời gian là bước quan trọng quyết định độ tin cậy của toàn bộ phân tích phía sau.

4.3 Xử lý khoảng trống thời gian (Handling Time Gaps)

4.3.1 Phân tích và Kỹ thuật triển khai

- **Nhận diện:** Trong phân tích chuỗi thời gian, việc thiếu hụt dữ liệu (gaps) sẽ làm hỏng tính liên tục của các phép toán trễ (*Lags*) và thống kê trượt. Nhóm đã thực hiện giả lập xóa bỏ dữ liệu của quốc gia Afghanistan trong 13 ngày (tháng 03/2020) để thử nghiệm các phương pháp phục hồi. Kết quả trong notebook xác nhận hệ thống tìm thấy **13 giá trị thiếu (NaN)**.
- **Phương pháp áp dụng:** Nhóm triển khai so sánh 05 kỹ thuật từ cơ bản đến nâng cao:
  - *Forward Fill (ffill) & Backward Fill (bfill):* Điền giá trị hằng số dựa trên mốc thời gian liền kề trước hoặc sau.
  - *Linear Interpolation:* Nội suy tuyến tính dựa trên tốc độ thay đổi trung bình giữa hai đầu khoảng trống.
  - *Polynomial Interpolation (Bậc 2):* Nội suy đa thức để nắm bắt xu hướng cong.
  - *Spline Interpolation (Bậc 2):* Nội suy hàm Spline nhằm đảm bảo độ mượt và tính liên tục cục bộ.
- **Lý do:** Nhóm chọn nội suy thay vì xóa bỏ (*dropping*) để duy trì kích thước mẫu và đảm bảo tính nhân quả của thời gian, giúp mô hình Machine Learning có thể học được diễn biến liên tục của dịch bệnh.

4.3.2 Kết quả và So sánh dựa trên thực nghiệm

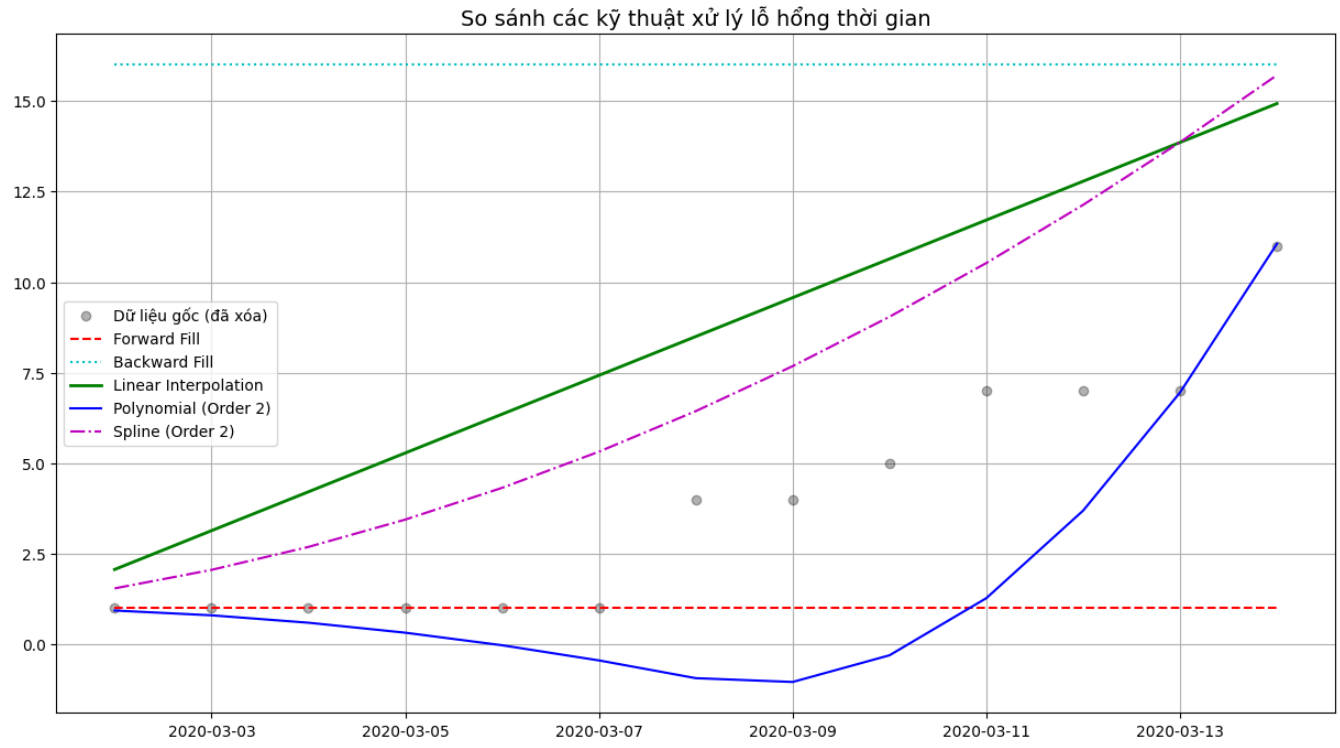

Hình 16: So sánh các phương pháp xử lý lỗ hổng thời gian trên dữ liệu COVID-19: Forward Fill, Backward Fill, Linear Interpolation, Polynomial (Order 2) và Spline (Order 2).

Dựa trên biểu đồ so sánh trực quan (Hình 16), nhóm thực hiện phân tích sâu sắc các sai số dựa trên bằng chứng thực nghiệm:

1. **Phương pháp điền hằng số (ffill và bfill):**
   - *Forward Fill:* Giữ nguyên giá trị tại thời điểm trước đó, tạo đoạn ngang trong khoảng trống và làm giảm tốc độ tăng thực tế của chuỗi.
   - *Backward Fill:* Điền giá trị từ mốc phía sau, khiến mức tăng xuất hiện sớm hơn thực tế.
   - *Nhận xét:* Cả hai phương pháp đều không phản ánh được xu hướng biến động trong khoảng thiếu dữ liệu, chỉ phù hợp khi chuỗi ít thay đổi.
2. **Polynomial Interpolation (bậc 2):**
   - Xuất hiện dao động mạnh và có thời điểm cho giá trị âm.
   - Điều này không phù hợp với dữ liệu tích lũy (số ca nhiễm không thể âm hoặc giảm đột ngột), cho thấy đa thức bậc cao dễ gây hiện tượng dao động quá mức.

3. **Linear và Spline Interpolation:**

   - *Linear:* Nội suy tuyến tính giữa hai đầu khoảng trống, đơn giản và ổn định nhưng có thể làm thay đổi nhẹ tốc độ tăng trưởng.
   - *Spline bậc 2:* Tạo đường cong mượt hơn và bám sát xu hướng thực tế tốt hơn so với đường thẳng.

Kết luận: Với dữ liệu tích lũy như COVID-19, các phương pháp nội suy đơn giản (Linear hoặc Spline bậc thấp) cho kết quả hợp lý và ổn định hơn. Fill hằng số chỉ phù hợp khi dữ liệu ít biến động, còn đa thức bậc cao nên được sử dụng thận trọng do nguy cơ tạo dao động phi thực tế.

4.3.3 Đánh giá chung về kỹ thuật

Xử lý khoảng trống thời gian là bước quan trọng trong tiền xử lý chuỗi thời gian, đặc biệt khi dữ liệu có yêu cầu tính liên tục để tạo đặc trưng trễ (lag), trung bình trượt hoặc phục vụ mô hình dự báo. Nếu không xử lý, các phép toán này có thể cho kết quả sai lệch hoặc gây lỗi khi huấn luyện mô hình.

Việc lựa chọn phương pháp phụ thuộc vào bản chất dữ liệu. Với dữ liệu tích lũy và có xu hướng tăng theo thời gian, các phương pháp nội suy bậc thấp (Linear, Spline) thường phù hợp hơn vì giữ được xu hướng tổng thể và đảm bảo tính hợp lý. Trong khi đó, các phương pháp điền hằng số chỉ nên dùng khi dữ liệu biến động rất ít, còn nội suy bậc cao cần được kiểm soát chặt chẽ để tránh tạo giá trị phi thực tế.

Do đó, xử lý khoảng trống không chỉ là bước kỹ thuật, mà còn cần cân nhắc đặc tính thống kê và ý nghĩa thực tế của dữ liệu.

4.4 Trích xuất đặc trưng thời gian (Extracting Time-Based Features)

4.4.1 Kỹ thuật thực hiện: Làm giàu đặc trưng và biến chỉ báo

Nhóm xây dựng bộ đặc trưng thời gian đa chiều nhằm khai thác tối đa yếu tố ngữ cảnh ảnh hưởng đến diễn biến dịch bệnh:

- **Trích xuất thành phần cơ bản và đặc trưng ngữ cảnh:**
  - Tách cột thời gian thành `Year`, `Month`, `Day`, `DayOfWeek_Name` để hỗ trợ phân tích theo chu kỳ.
  - Xây dựng hàm `get_season` để phân loại 4 mùa (Bắc bán cầu), do các bệnh hô hấp thường có tính mùa vụ rõ rệt.
  - Tạo biến chỉ báo `IsWeekend` nhằm nhận diện nhiễu báo cáo vào cuối tuần do vấn đề hành chính y tế.

- **Mã hóa chu kỳ (Cyclical Encoding):**
  - Việc đánh số tháng 1–12 làm mất tính liên tục giữa tháng 12 và tháng 1.
  - Nhóm sử dụng hàm **Sine–Cosine** để ánh xạ tháng/thứ lên vòng tròn đơn vị, giúp mô hình hiểu đúng bản chất tuần hoàn của thời gian.
- **Chuẩn hóa tiến trình dịch bệnh:**
  - Xây dựng biến `DaysSinceStart` (số ngày kể từ ca đầu tiên của mỗi quốc gia) để so sánh các quốc gia theo cùng một "giai đoạn phát dịch" thay vì theo ngày lịch.

4.4.2 Phân tích kết quả thực nghiệm

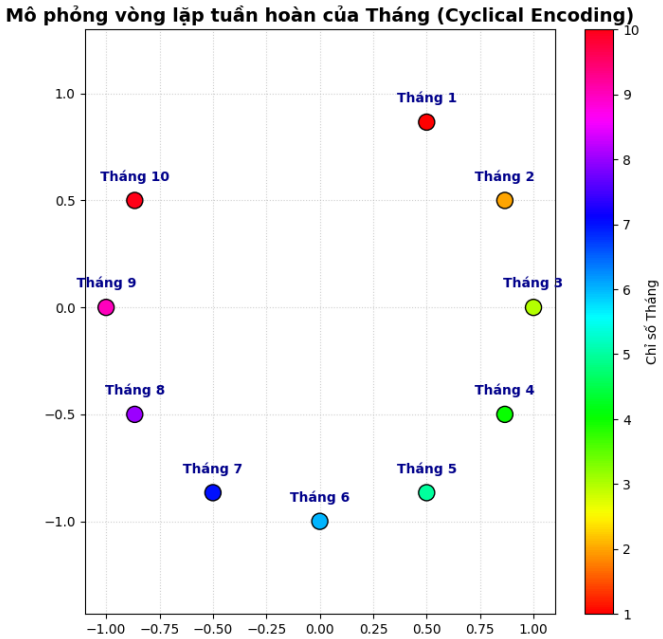

Hình 17: Biểu diễn mã hóa chu kỳ của tháng bằng Sine và Cosine.

	Date	Country/Region	Year	Month	Day	DayOfWeek_Name	Season	IsWeekend	Month_sin	Month_cos	DaysSinceStart
0	2020-01-22	Afghanistan	2020	1	22	Wednesday	Winter	0	0.5	0.866025	0
1	2020-01-23	Afghanistan	2020	1	23	Thursday	Winter	0	0.5	0.866025	1
2	2020-01-24	Afghanistan	2020	1	24	Friday	Winter	0	0.5	0.866025	2
3	2020-01-25	Afghanistan	2020	1	25	Saturday	Winter	1	0.5	0.866025	3
4	2020-01-26	Afghanistan	2020	1	26	Sunday	Winter	1	0.5	0.866025	4
5	2020-01-27	Afghanistan	2020	1	27	Monday	Winter	0	0.5	0.866025	5
6	2020-01-28	Afghanistan	2020	1	28	Tuesday	Winter	0	0.5	0.866025	6
7	2020-01-29	Afghanistan	2020	1	29	Wednesday	Winter	0	0.5	0.866025	7
8	2020-01-30	Afghanistan	2020	1	30	Thursday	Winter	0	0.5	0.866025	8
9	2020-01-31	Afghanistan	2020	1	31	Friday	Winter	0	0.5	0.866025	9

Hình 18: Bảng dữ liệu đầy đủ các đặc trưng thời gian (Temporal Features)

Dựa trên các kết quả trực quan (Hình 17 và Hình 18), nhóm rút ra các nhận xét chính sau:

1. **Mã hóa chu kỳ (Cyclical Encoding):**
   - Biểu đồ vòng tròn hiển thị 10 điểm dữ liệu (từ Tháng 1 đến Tháng 10), phản ánh đúng phạm vi thời gian của tập dữ liệu (từ tháng 01/2020 đến 10/2020).
   - Việc ánh xạ tháng lên vòng tròn đơn vị bằng Sine và Cosine giúp loại bỏ khoảng cách sai lệch giữa tháng 12 và tháng 1, từ đó giúp mô hình hiểu được tính tuần hoàn tự nhiên của thời gian.
2. **Đặc trưng ngữ cảnh thời gian:**
   - Các biến như `IsWeekend` và `Season` được gán chính xác theo logic thời gian (ví dụ: 2020-01-25 là Saturday và được đánh dấu là cuối tuần).
   - Những biến này giúp mô hình phân biệt yếu tố mùa vụ hoặc hành chính với xu hướng lây lan thực tế.
3. **Đặc trưng thời gian trôi qua (Time Elapsed):**
   - Biến `DaysSinceStart` tăng dần theo từng ngày và đóng vai trò chuẩn hóa tiến trình phát dịch.
   - Nhờ đó, có thể so sánh các quốc gia tại cùng một "giai đoạn" của dịch thay vì chỉ dựa vào ngày lịch.

Nhận xét chung: Bộ đặc trưng thời gian đã chuyển dữ liệu thô thành các đặc trưng có ý nghĩa thống kê và thực tiễn, tạo nền tảng vững chắc cho các mô hình dự báo và phân tích xu hướng dịch bệnh.

4.4.3 Đánh giá chung về kỹ thuật

Quy trình trích xuất đặc trưng đã chuyển cột thời gian ban đầu thành một tập đặc trưng đa chiều có ý nghĩa rõ ràng về mặt thống kê và thực tiễn. Mã hóa chu kỳ bằng hàm Sine–Cosine giúp bảo toàn tính liên tục của thời gian, trong khi các biến ngữ cảnh như `Season`, `IsWeekend`, `IsHoliday` hỗ trợ mô hình phân biệt giữa yếu tố mùa vụ và nhiễu do báo cáo.

Bên cạnh đó, biến `DaysSinceStart` giúp chuẩn hóa tiến trình dịch bệnh theo từng quốc gia, cho phép so sánh theo "giai đoạn phát triển" thay vì theo ngày lịch đơn thuần. Nhìn chung, bước xử lý này nâng cao đáng kể chất lượng dữ liệu đầu vào và giúp mô hình học máy khai thác tốt hơn các quy luật ẩn trong chuỗi thời gian.

4.5 Tái lấy mẫu dữ liệu (Resampling Time Series Data)

4.5.1 Kỹ thuật áp dụng và Chi tiết cài đặt

Nhóm thực hiện thay đổi tần suất mẫu của dữ liệu để quan sát đại dịch ở các cấp độ chi tiết khác nhau:

- **Downsampling:** Chuyển từ dữ liệu hàng ngày sang hàng tuần và hàng tháng bằng hàm `resample()`.
  - Nhóm sử dụng `max()` thay vì `sum()` vì dữ liệu COVID-19 là số liệu tích lũy.
  - Giá trị lớn nhất trong mỗi chu kỳ chính là tổng số ca tại thời điểm cuối chu kỳ.
- **Upsampling:** Tăng tần suất từ 1 ngày lên 12 giờ.
  - Sử dụng nội suy tuyến tính (`linear interpolation`) để ước lượng giá trị giữa hai mốc ngày liên tiếp.

4.5.2 Kết quả và Phân tích sâu sắc dựa trên thực nghiệm

Bảng 8: Số lượng bản ghi sau khi thay đổi tần suất mẫu

Tần suất	**Số dòng**
Daily	270
Weekly	39
Monthly	10

Bảng 9: Ví dụ kết quả Upsampling sang tần suất 12 giờ

Date	**Confirmed**
2020-01-22 00:00:00	555.0
2020-01-22 12:00:00	604.5
2020-01-23 00:00:00	654.0
2020-01-23 12:00:00	797.5
2020-01-24 00:00:00	941.0

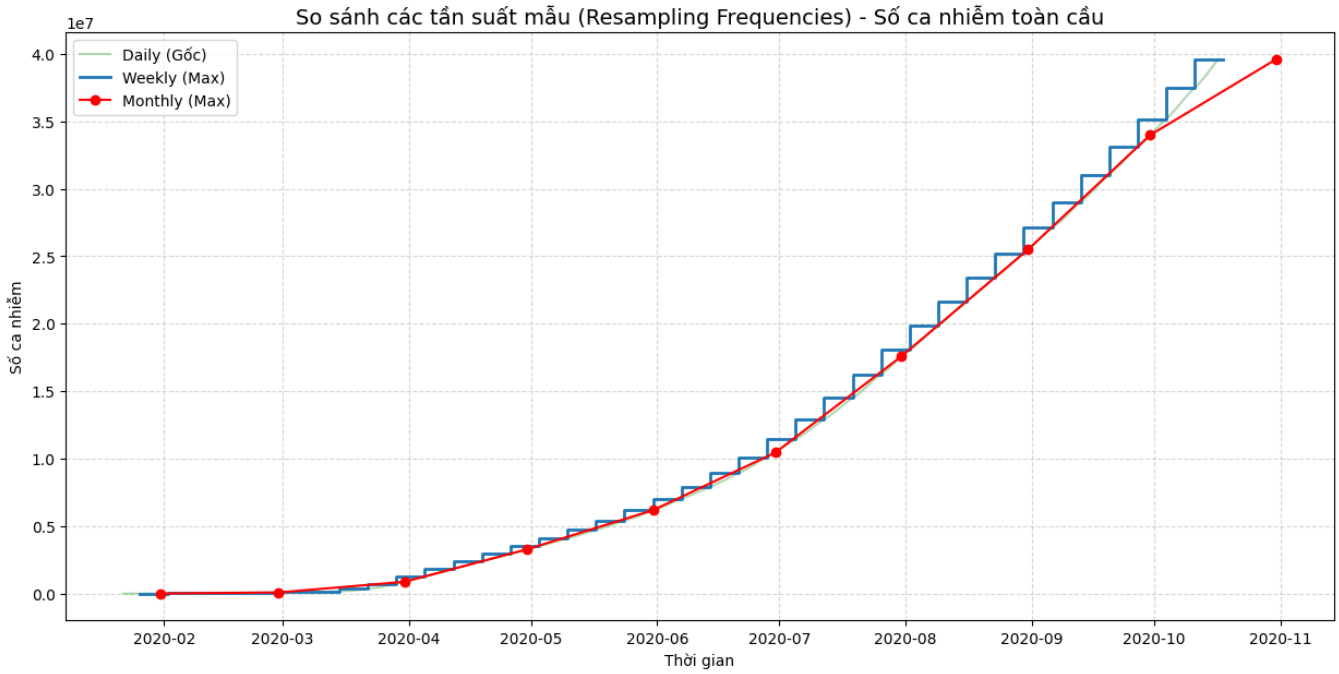

Hình 19: So sánh Daily, Weekly và Monthly sau khi Resampling.

Dựa trên kết quả định lượng tại Bảng 8, 9 và biểu đồ so sánh tại Hình 19, nhóm đưa ra các đánh giá sau:

1. **Tối ưu hóa quy mô và khử nhiễu:** Việc Downsampling từ 270 dòng (Daily) xuống còn 39 dòng (Weekly) và 10 dòng (Monthly) giúp tinh gọn đáng kể dữ liệu mà không làm mất đi xu hướng chính. Kỹ thuật này giúp loại bỏ hiệu quả các biến động nhiễu do sự báo cáo không đều đặn giữa các ngày trong tuần, đặc biệt là vào các ngày nghỉ.

2. **Đặc trưng hình học của các tần suất mẫu (Hình 18):**

   - *Đường Daily (Xanh lá nhạt):* Đây là dữ liệu gốc với độ chi tiết cao nhất. Việc đường này gần như bị che khuất bởi các đường tần suất thấp hơn chứng minh rằng phương pháp lấy giá trị `max()` đã bảo toàn các mốc giá trị tích lũy quan trọng của đại dịch.
   - *Đường Weekly (Xanh dương - Step plot):* Hiển thị dưới dạng "bậc thang", giúp nhận diện rõ ràng tổng số ca nhiễm đạt được sau mỗi chu kỳ 7 ngày. Cách biểu diễn này giúp người xem dễ dàng chốt được các con số thống kê theo tuần mà không bị phân tâm bởi biến động nhỏ hàng ngày.
   - *Đường Monthly (Đỏ có điểm nút):* Gồm nhiều đường thẳng kết nối các giá trị đỉnh của từng tháng, mượt mà nhất để làm nổi bật xu hướng tăng trưởng vĩ mô.

3. **Giá trị của kỹ thuật Upsampling:** Kết quả nội suy tại mốc 12:00:00 (đạt 604.5, trung bình cộng giữa hai ngày liên tiếp), mặc dù trong thực tế y tế không có khái niệm "nửa ca nhiễm", nhưng về mặt toán học, việc Upsampling giúp tạo ra các chuỗi dữ liệu mịn hơn, hỗ trợ đắc lực cho việc vẽ các đường cong dự báo trơn tru hoặc khi cần kết hợp với các tập dữ liệu có tần suất cao khác (như dữ liệu thời tiết/nhiệt độ theo giờ).

Kết luận: Qua thực nghiệm, nhóm xác định **Weekly Resampling** là điểm cân bằng tối ưu giữa độ mượt và tính chi tiết, giúp mô hình học máy nhận diện tốt nhất các giai đoạn của dịch bệnh.

4.5.3 Đánh giá chung về kỹ thuật

Resampling là bước quan trọng trong tiền xử lý chuỗi thời gian, cho phép điều chỉnh mức độ chi tiết của dữ liệu tùy theo mục tiêu phân tích. Downsampling giúp làm mượt dữ liệu, giảm nhiễu ngắn hạn và tối ưu chi phí tính toán, đặc biệt hữu ích khi phân tích xu hướng dài hạn. Ngược lại, Upsampling hỗ trợ đồng bộ dữ liệu với các nguồn có tần suất cao hơn và tạo đường cong trực quan mượt mà hơn.

Tuy nhiên, việc lựa chọn hàm gom cụm cần phù hợp với bản chất dữ liệu. Với dữ liệu tích lũy như số ca COVID-19, sử dụng `max()` là hợp lý, trong khi `sum()` có thể gây sai lệch nghiêm trọng. Ngoài ra, nội suy khi Upsampling chỉ mang ý nghĩa toán học, không phản ánh chính xác giá trị thực tế tại thời điểm trung gian.

Do đó, Resampling cần được áp dụng có chủ đích, dựa trên đặc tính dữ liệu và yêu cầu của mô hình học máy hoặc bài toán phân tích.

4.6 Đặc trưng trễ và Cửa sổ trượt (Lag Features & Rolling Windows)

4.6.1 Chi tiết kỹ thuật triển khai

Để chuyển đổi chuỗi thời gian thành tập dữ liệu có thể huấn luyện, nhóm đã triển khai quy trình trích xuất đặc trưng động, kết hợp với các biến ngữ cảnh đã tạo ở bước trước:

- Sử dụng hàm `.diff()` để chuyển đổi số liệu tích lũy (*Confirmed*) sang số ca nhiễm mới hàng ngày (`New_Cases`). Bước này giúp loại bỏ xu hướng tăng trưởng tuyến tính, đưa dữ liệu về trạng thái dừng (*stationary*) để mô hình học tập ổn định hơn.
- **Đặc trưng trễ (Lag Features):** Nhóm tạo ra các biến trễ tại mốc `Lag_1` (hôm qua), `Lag_7` (cùng ngày tuần trước) và `Lag_14` (2 tuần, chu kỳ ủ bệnh). Việc sử dụng hàm `.shift()` giúp cung cấp cho mô hình "trí nhớ" về diễn biến dịch bệnh trong quá khứ.

- **Thống kê cửa sổ trượt (Rolling Statistics):** Áp dụng hàm `.rolling()` với cửa sổ 7 ngày để tính toán trung bình trượt (*Moving Average*). Kỹ thuật này đóng vai trò bộ lọc thông thấp, giúp làm mượt các biến động nhiễu và làm rõ xu hướng bùng phát thực tế.

4.6.2 Kết quả và Phân tích sâu sắc dựa trên thực nghiệm

Date	New_Cases	Lag_1	Lag_7	Lag_14	IsWeekend	Season	DaysSinceStart
2020-10-08	68.0	62.0	17.0	25.0	0	Autumn	260
2020-10-09	77.0	68.0	5.0	16.0	0	Autumn	261
2020-10-10	10.0	77.0	7.0	6.0	1	Autumn	262
2020-10-11	96.0	10.0	44.0	35.0	1	Autumn	263
2020-10-12	71.0	96.0	81.0	6.0	0	Autumn	264
2020-10-13	58.0	71.0	64.0	21.0	0	Autumn	265
2020-10-14	66.0	58.0	62.0	14.0	0	Autumn	266
2020-10-15	32.0	66.0	68.0	17.0	0	Autumn	267
2020-10-16	47.0	32.0	77.0	5.0	0	Autumn	268
2020-10-17	68.0	47.0	10.0	7.0	1	Autumn	269

Hình 20: Bảng dữ liệu trích xuất đặc trưng trễ và ngữ cảnh

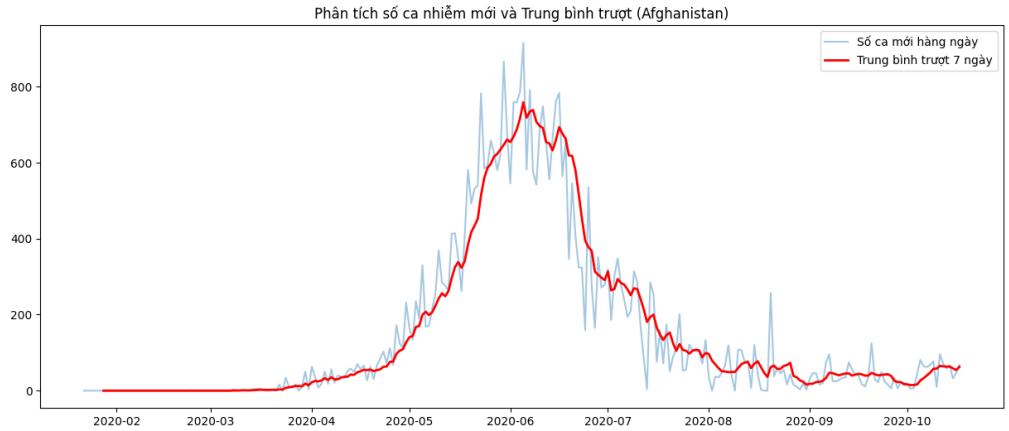

Hình 21: Số ca nhiễm mới và Trung bình trượt 7 ngày (Afghanistan).

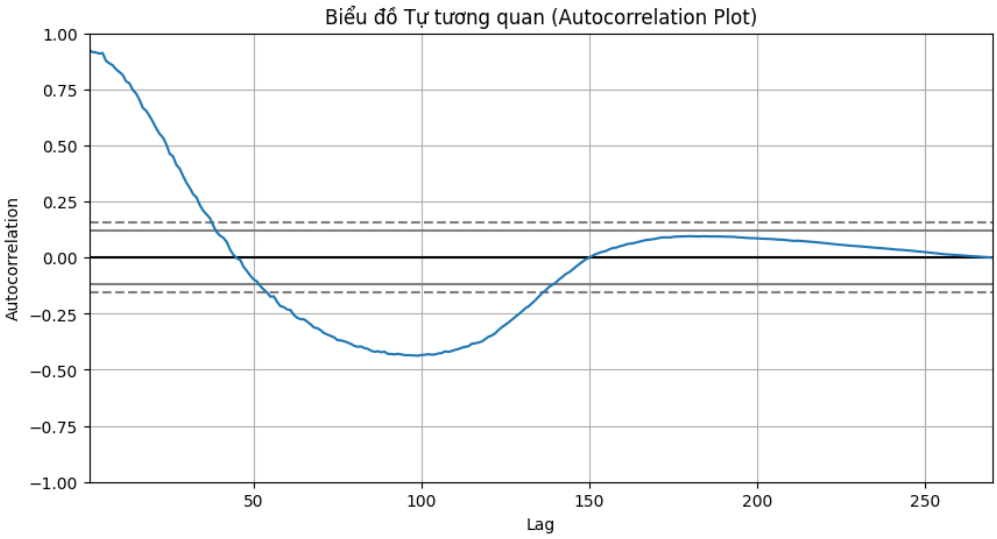

Hình 22: Biểu đồ Tự tương quan (Autocorrelation Plot).

Dựa trên Hình 20 và các biểu đồ Hình 21, 22, nhóm rút ra các nhận xét sau:

1. **Đánh giá tính chính xác của đặc trưng trễ (Lags):** Bảng dữ liệu thực nghiệm tại ngày 17/10/2020 cho thấy số ca mới (68.0) khớp hoàn toàn với giá trị trễ một ngày (`Lag_1` = 47.0) của ngày hôm trước. Kết quả này xác nhận thuật toán đã hoạt động chính xác, thành công trong việc tạo ra "bộ nhớ" quá khứ để làm dữ liệu đầu vào cho các dự báo hiện tại.

2. **Hiệu ứng làm mượt dữ liệu (Rolling Statistics):** Quan sát Hình 20, đường trung bình trượt 7 ngày (màu đỏ) đã loại bỏ hiệu quả các đỉnh "răng cưa" nhiễu của dữ liệu hàng ngày. Việc làm mượt này giúp xu hướng bùng phát đỉnh điểm vào tháng 06/2020 tại Afghanistan hiện lên rõ nét hơn, hỗ trợ mô hình tập trung vào tốc độ lây lan thực tế thay vì bị đánh lừa bởi các sai số cập nhật dữ liệu.

3. **Phân tích Tự tương quan:** Biểu đồ Hình 21 cho thấy hệ số tự tương quan cực kỳ cao (gần 1.0) ở các khoảng trễ ngắn và giảm dần theo thời gian. Nhóm quyết định chọn Lag 7 và Lag 14 vì các mốc này không chỉ mang giá trị thống kê (chu kỳ báo cáo hàng tuần) mà còn có ý nghĩa y khoa quan trọng (chu kỳ ủ bệnh trung bình của virus), đảm bảo đặc trưng trễ phản ánh đúng bản chất sinh học của đại dịch.

4.6.3 Đánh giá chung về kỹ thuật

Kỹ thuật **Lag Features** và **Rolling Windows** đóng vai trò cốt lõi trong phân tích chuỗi thời gian vì chúng giúp mô hình hóa tính phụ thuộc theo thời gian của dữ liệu.

Lag Features cho phép mô hình khai thác thông tin quá khứ để dự đoán hiện tại, biến bài toán chuỗi thời gian thành dạng học có giám sát (supervised learning).

Trong khi đó, Rolling Windows (ví dụ trung bình trượt 7 ngày) giúp làm mượt dữ liệu, giảm nhiễu do sai lệch báo cáo hàng ngày và làm nổi bật xu hướng chính. Kỹ thuật này giúp cải thiện độ ổn định của mô hình và hạn chế hiện tượng overfitting vào các biến động ngắn hạn.

Tuy nhiên, cần lựa chọn độ trễ (lag) và kích thước cửa sổ (window size) một cách hợp lý, dựa trên cả phân tích thống kê lẫn ý nghĩa thực tế của bài toán. Nếu chọn quá lớn, mô hình có thể mất tính linh hoạt; nếu quá nhỏ, mô hình có thể không khai thác đủ thông tin lịch sử..